

Università di Pisa

Laurea Magistrale in Informatica

Computational Mathematics for Learning and Data Analysis

Dispensa del corso

Basata sulle lezioni di

Prof. Antonio Frangioni (Ottimizzazione)

Prof. Alice Cortinovis (Analisi Numerica Lineare)

A.A. 2025/2026

Questa dispensa integra le slide ufficiali, le note di Frangioni (2025/26) e gli appunti dalle esercitazioni di Cortinovis. È redatta in italiano con terminologia tecnica in inglese.

Obiettivo: copertura completa di tutto il programma del corso.

Indice

Percorso di Studio ad Interni	7
Introduzione al Corso	11
I Livello 1 — Core Ottimizzazione del Progetto	13
1 Il Progetto ML-25: ELM con Regularizzazione LASSO	15
1.1 Formulazione del problema	15
1.2 Algoritmo A1: IRLS (Iteratively Reweighted Least Squares)	16
1.3 Algoritmo A2: Deflected Subgradient	17
1.3.1 Subgradiente del problema LASSO	17
1.3.2 Target level stepsize	17
1.3.3 Deflection	18
1.4 Confronto A1 vs A2	19
2 Ottimizzazione Non Vincolata — Metodi non-smooth	21
2.1 Funzioni non differenziabili	21
2.2 Metodo del subgradiente	21
2.3 Metodo del gradiente prossimale	22
2.4 Metodi bundle	22
II Livello 2 — Intorno Ottimizzazione (Esame Orale)	25
3 Ottimizzazione Non Vincolata	27
3.1 Richiami di analisi in più variabili	27
3.1.1 Gradiente, Hessiana, sviluppo di Taylor	27
3.1.2 Condizioni di ottimalità	27
3.1.3 Classi di regolarità importanti	28
3.1.4 Funzioni convesse	28
3.2 Metodi del gradiente (smooth)	28
3.2.1 Gradient Descent a passo fisso	28
3.2.2 Line Search adattiva	30
3.3 Metodo di Newton multivariato	30


3.4	Metodi quasi-Newton	31
3.4.1	Aggiornamento BFGS	31
3.5	Gradiente Coniugato per funzioni quadratiche	31
3.6	Metodi del gradiente deflesso (smooth)	32
III Livello 3 — Core NLA del Progetto		35
4	Il Problema dei Minimi Quadrati	37
4.1	Formulazione	37
4.2	Equazioni normali	37
4.3	Soluzione via SVD	37
5	Fattorizzazioni Dirette per Sistemi Lineari	39
5.1	Fattorizzazione LU	39
5.2	Fattorizzazione LDL^T per matrici simmetriche	40
5.3	Fattorizzazione di Cholesky	40
5.4	Confronto e scelta dell'algoritmo	40
5.5	Esempi pratici	40
6	Metodi Iterativi per Sistemi Lineari	43
6.1	Motivazione: sistemi sparsi di grande scala	43
6.2	Spazi di Krylov	43
6.3	Gradiente Coniugato per sistemi SPD	43
6.3.1	Precondizionamento	43
6.4	Algoritmo di Arnoldi	44
6.5	GMRES	44
IV Livello 4 — Intorno NLA (Esame Orale)		47
7	Condizionamento e Stabilità	49
7.1	Numero di condizionamento	49
7.2	Aritmetica floating point	49
7.3	Stabilità degli algoritmi	50
7.3.1	Test a posteriori: analisi del residuo	51
8	Fattorizzazione QR	53
8.1	Definizione e teorema	53
8.2	Riflettori di Householder	53
8.3	Soluzione dei minimi quadrati con QR	54
9	Decomposizione a Valori Singolari (SVD)	55
9.1	Definizione e proprietà	55
9.2	Teorema di Eckart-Young (approssimazione di basso rango)	56

10 Norme e Matrici Ortogonali	57
10.1 Norme vettoriali	57
10.2 Matrici ortogonali	57
10.3 Norme di matrici	57
 V Livello 5 — Il Resto del Corso	 59
11 Background: Algebra Lineare	61
11.1 Prodotto matriciale e interpretazioni	61
11.2 Sistemi triangolari	61
11.3 Autovalori e forme quadratiche	61
 VI Livello 6 — Distanza dal Progetto	 63
12 Semplici Problemi di Ottimizzazione	65
12.1 Formulazione generale	65
12.1.1 Minimi locali vs globali	65
12.2 Ottimizzazione univariata (1D)	65
12.2.1 Golden Section Search	66
12.2.2 Metodo di Newton 1D	66
13 Ottimizzazione Vincolata	67
13.1 Formulazione e topologia	67
13.2 Condizioni KKT	67
13.2.1 Vincoli attivi e LICQ	67
13.2.2 Lemma di Farkas e dualità	68
13.3 Dualità Lagrangiana	68
13.4 Algoritmi per l'ottimizzazione vincolata	69
13.4.1 Gradiente proiettato	69
13.4.2 Metodo di Frank-Wolfe (Conditional Gradient)	69
13.4.3 Metodi barriera (Interior Point)	69
14 Riepilogo: Connessioni tra NLA e Ottimizzazione	71
 VII Domande d'Esame Orale	 73
15 Domande — Progetto ML-25 (ELM + LASSO)	77
16 Domande — Ottimizzazione Non-Smooth e Deflected Subgradient	81
17 Domande — Ottimizzazione Smooth e Intorno	87
18 Domande — Algebra Lineare Numerica	89

19 Domande — Ottimizzazione Vincolata e Argomenti Distanti	91
20 Domande Trasversali — Collegamenti NLA $\leftrightarrow$ Ottimizzazione	93
A Appendice: Richiami e Tabelle di Riferimento	95
A.1 Notazione	95
A.2 Costi computazionali principali	96
A.3 Tassi di convergenza degli algoritmi di ottimizzazione	96
A.4 Regole pratiche per l'esame	96

Percorso di Studio ad Intorni — Progetto ML-25

Questa dispensa è organizzata attorno a **6 livelli di priorità** centrati sul progetto ML-25 (ELM + LASSO con algoritmi IRLS e Deflected Subgradient). Studia dall'interno verso l'esterno: padroneggia perfettamente il Livello 1 prima di procedere.



Livello 1 — Core Ottimizzazione (critici per il progetto)

Questi argomenti *devono essere padroneggiati perfettamente*. Costituiscono la teoria diretta di entrambi gli algoritmi del progetto.

- **Subgradienti e subdifferenziale** $\partial f(x)$: definizione, calcolo per $\|w\|_1$, condizione di ottimalità $0 \in \partial f(w^*)$ (§2.1).
- **Algoritmo A1 — IRLS**: riformulazione smooth del LASSO tramite approssimazione quadratica di $|w_i|$, framework MM (Majorization-Minimization), convergenza lineare (§1.2).
- **Algoritmo A2 — Deflected Subgradient**: formula $d^i = \gamma^i g^i + (1-\gamma^i)d^{i-1}$, stepsize con target level, regole di deflection, convergenza $O(1/\varepsilon^2)$ (§1.3).
- **Complessità non-smooth vs smooth**: $O(1/\varepsilon^2)$ per convex Lipschitz, $O(1/\varepsilon)$ per smooth convex, $O(\log 1/\varepsilon)$ per fortemente convex (§1.3.1).
- **Record value** $\bar{f}^i = \min_{h \leq i} f(x^h)$: la sequenza non è monotona, ma il record converge.

- **Polyak stepsize** $\alpha^i = (f^i - f^*)/\|g^i\|^2$ e target level stepsize (§1.3).

Riferimento principale: *OPT/5-nonsmooth.pdf* (slide 3–15); Capitolo 2 di questa dispensa.

Livello 2 — Intorno Ottimizzazione (esame orale, approcci alternativi)

Argomenti correlati al progetto: il professore può chiederli per approfondire la teoria o valutare la comprensione degli approcci alternativi.

- **L -smooth e τ -fortemente convessa**: definizioni, lemma di discesa, tassi di convergenza del gradient descent (§3.1.3).
- **Deflected gradient methods (smooth)**: NCG (Fletcher-Reeves, Polak-Ribière), Heavy Ball — analoghi smooth di A2. Utili per capire la deflection (§3.6).
- **Proximal gradient / ISTA / FISTA**: soluzione alternativa per $f = h + \lambda\|\cdot\|_1$ con convergenza $O(1/k)$ e $O(1/k^2)$ (§2.3).
- **Bundle methods**: approccio sofisticato non-smooth, modello piecewise-linear (§2.4).
- **Condizioni KKT**: formulazione con LICQ, condizioni del secondo ordine (§13.2).
- **Metodo di Newton multivariato e BFGS**: passo cubico vs quadratico (§3.3).

Riferimento: *OPT/4-smooth.pdf* (slide 9–19); *OPT/3-unconstrained.pdf* (slide 9–16).

Livello 3 — Core NLA (critici per il progetto)

Questi sono i prerequisiti numerici diretti del sotto-passo di IRLS.

- **Equazioni normali** $X^\top X w = X^\top y$: derivazione come condizione di ottimalità dei minimi quadrati, rango pieno, pseudoinversa (§4.2).
- **Fattorizzazione di Cholesky**: per $Q \succ 0$, $Q = LL^\top$, costo $n^3/3$, uso diretto nel sotto-problema IRLS (§5.3).
- **Gradiente Coniugato (CG)**: metodo iterativo alternativo per sistemi SPD grandi; convergenza $\leq 2 \left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1} \right)^k$ (§6.3).
- **Condizionamento** $\kappa(A)$: perché $\kappa(X^\top X) = \kappa(X)^2$ — le equazioni normali peggiorano il condizionamento al quadrato (§7.1).

Riferimento: *NLA/4-leastsquares-normal.pdf*; *NLA/20-chol.pdf*; *NLA/5-CG.pdf*.

Livello 4 — Intorno NLA (esame orale, contesto numerico)

- **Fattorizzazione LU:** background per Cholesky, pivoting per stabilità (§5.1).
- **Condizionamento LS specifico:** bound sull'errore relativo $\|\tilde{x} - x\|/\|x\| \leq \kappa \cdot \|\tilde{y} - y\|/\|y\|$ (§7.1).
- **SVD:** definizione, Eckart-Young, pseudoinversa — non usata direttamente nel progetto ma spesso chiesta (§9).
- **QR (Householder):** alternativa stabile alle equazioni normali; riflettori $H = I - 2vv^\top/\|v\|^2$ (§8.2).
- **Stabilità backward:** definizione e prova per il prodotto interno (§7.3).

Riferimento: *NLA/12-conditioning.pdf*; *NLA/9-QR.pdf*; *NLA/14-stability.pdf*.

Livello 5 — Tutto il resto che potrebbe chiedere

- **GMRES e Arnoldi:** metodi di Krylov per sistemi non-SPD; il nostro sotto-problema è sempre SPD, ma potrebbe esser chiesto per contrasto (§6.5).
- **Tikhonov:** $\|Ax - b\|^2 + \delta\|x\|^2$, soluzione via SVD (§4.1).
- **Norme matriciali:** norma spettrale $\|A\|_2 = \sigma_1$, Frobenius, sub-moltiplicatività (§10.3).
- **Approssimazione di rango basso:** teorema di Eckart-Young (§9.2).

Livello 6 — Distante dal progetto (copertura di completezza)

- **Ottimizzazione vincolata:** KKT completo, dualità lagrangiana, metodi barrier e active set (§13).
- **Ottimizzazione univariata:** Golden Section Search, Newton 1D (§12.2).
- **Frank-Wolfe / Conditional Gradient:** solo per contesto (§13.4.2).
- **Ottimizzazione combinatoria:** non coperta in questa dispensa.

I file OPT/6, 7 (ottimizzazione vincolata) e NLA/17-18 (GMRES) sono classificati "non necessari" dalla guida teorica del progetto per chi deve solo superare il progetto. Studiare se rimane tempo.

Percorso di studio consigliato (guida_teorica.pdf §8.3)

Ordine ottimale:

1. OPT/3 slide 1–16: norme, gradiente, Hessiano, convessità.
2. NLA/3 e NLA/4: minimi quadrati ed equazioni normali.

3. NLA/20: Cholesky. Ora capisci il sotto-problema dell'IRLS.
4. OPT/4 slide 9–19: L -smoothness, convessità forte, deflected gradient.
5. NLA/5: CG. Ora capisci i solver alternativi per IRLS.
6. OPT/5 intero: subgradienti, Polyak, target level, deflected subgradient.
7. Opzionale: NLA/12–13 condizionamento, NLA/21 esempi pratici.

Totale essenziale: circa **175 pagine di slide** (non di testo denso).

Introduzione al Corso

Il corso di **Computational Mathematics for Learning and Data Analysis** è tenuto da due professori:

- **Prof. Antonio Frangioni** — parte di *ottimizzazione*: risoluzione di $\min_{x \in S} f(x)$ per classi crescenti di funzioni e insiemi ammissibili.
- **Prof. Alice Cortinovis** — parte di *analisi numerica lineare (NLA)*: risoluzione efficiente e accurata del problema dei minimi quadrati $\min_x \|Ax - b\|^2$ e dei sistemi lineari.

Le due parti sono strettamente interconnesse: molti algoritmi di ottimizzazione richiedono la risoluzione di sistemi lineari come sotto-passo (es. il passo di Newton). Capire entrambe è fondamentale.

Prerequisiti: algebra lineare (spazi vettoriali, autovalori), analisi (Taylor, derivate parziali), nozioni di programmazione (Matlab/Python).

Parte I

Livello 1 — Core Ottimizzazione del Progetto

Capitolo 1

Il Progetto ML-25: ELM con Regularizzazione LASSO

1.1 Formulazione del problema

Il progetto riguarda l'**Extreme Learning Machine (ELM)**: una rete neurale a **uno strato nascosto** in cui i pesi del primo strato W_1 sono fissati casualmente e solo i pesi dell'**output** $w \in \mathbb{R}^n$ vengono **ottimizzati**.

La **feature matrix** $X \in \mathbb{R}^{m \times n}$ è data da:

$$X_{ij} = \sigma(\langle W_1^{(j)}, x_i \rangle), \quad W_1^{(j)} \sim \mathcal{N}(0, I), \text{ fissato.}$$

Il problema di addestramento con regularizzazione LASSO è:

$$\min_{w \in \mathbb{R}^n} f(w) = \underbrace{\|Xw - y\|_2^2}_{g(w) \text{ smooth}} + \lambda \underbrace{\|w\|_1}_{h(w) \text{ non-smooth}}, \quad \lambda > 0. \quad (1.1)$$

Proposizione 1.1 (Proprietà del problema LASSO). • f è convessa (somma di convesse).
È strettamente convessa sse X ha rango pieno colonna, cioè $X^\top X \succ 0$.

- $g(w) = \|Xw - y\|^2$ è L -smooth con $L = 2\lambda_{\max}(X^\top X)$ e τ -fortemente convessa con $\tau = 2\lambda_{\min}(X^\top X)$.
- f non è smooth: il termine $\|w\|_1$ non è differenziabile in $w_i = 0$.
- La condizione di ottimalità è $0 \in \partial f(w^*)$, che componente per componente diventa:

$$[X^\top(Xw^* - y)]_j + \lambda s_j^* = 0, \quad s_j^* \in \partial |w_j^*|.$$

Per $w_j^* \neq 0$: $s_j^* = \text{sign}(w_j^*)$. Per $w_j^* = 0$: $|[X^\top(Xw^* - y)]_j| \leq \lambda$.

Osservazione 1.1 (Numero di condizione del sotto-problema). Il **sotto-problema** lineare di **IRLS** richiede di risolvere $A_k w = b$ con $A_k = X^\top X + 2\lambda W_k^\top W_k \succ 0$. Il numero di condizione $\kappa(A_k)$ dipende da $\kappa(X)^2$ (le equazioni normali peggiorano la conditioning al quadrato). Per $\kappa(X) \gg 1$, il CG può essere preferibile a Cholesky per mantenere l'accuratezza.

1.2 Algoritmo A1: IRLS (Iteratively Reweighted Least Squares)

L'idea chiave è *approssimare la norma L1 con una forma quadratica attorno all'iterato corrente*:

$$|w_i| \approx \frac{w_i^2}{|w_{k,i}|} = \frac{w_i^2}{\sqrt{w_{k,i}^2}}, \quad \text{per } w_{k,i} \neq 0.$$

Definendo la *matrice dei pesi* $W_k = \text{diag}(\max(|w_{k,i}|, \varepsilon_{\text{thr}})^{-1/2})_{i=1}^n$ con $\varepsilon_{\text{thr}} \in [10^{-6}, 10^{-10}]$ per evitare la divisione per zero, l'*approssimazione del termine L1* diventa:

$$\lambda \|w\|_1 \approx \lambda \|W_k w\|_2^2 = \lambda w^\top W_k^\top W_k w.$$

Algoritmo: IRLS — Iteratively Reweighted Least Squares

Input: X, y, λ ; tolleranza ε_{thr} ; $\varepsilon_{\text{stop}}$; w_0 (es. $w_0 = 0$).

1. Per $k = 0, 1, 2, \dots$:
2. Calcola $W_k = \text{diag}(\max(|w_{k,i}|, \varepsilon_{\text{thr}})^{-1/2})_{i=1}^n$.
3. *Risolvi il sistema lineare SPD*:

$$\underbrace{(X^\top X + 2\lambda W_k^\top W_k)}_{A_k \succ 0} w_{k+1} = X^\top y$$

tramite *Cholesky* ($O(n^3/3)$) o *CG* (per n grande).

4. *Criteri di arresto*:

$$\frac{\|w_{k+1} - w_k\|}{\max(1, \|w_k\|)} < \varepsilon_{\text{stop}} \quad \text{oppure} \quad \frac{f(w_{k+1}) - f(w_k)}{f(w_k)} < \varepsilon_{\text{stop}}.$$

5. Fine per.

Output: $w^* \approx w_k$.

Osservazione 1.2 (Framework MM). IRLS è un caso del *framework Majorization-Minimization* (MM): ad ogni passo si costruisce una *funzione surrogate* $Q(w | w_k) \geq f(w)$ con uguaglianza in w_k , e si minimizza Q . Questo *garantisce* $f(w_{k+1}) \leq f(w_k)$ (*discesa monotona*), a differenza del subgradiente.

Teorema 1.1 (Convergenza di IRLS). *Se X ha rango pieno colonna ($X^\top X \succ 0$), allora la sequenza $\{w_k\}$ generata da IRLS converge alla soluzione ottima w^* del problema LASSO. Il *tasso* di convergenza è *tipicamente* lineare ($O(c^k)$ con $c < 1$) nella pratica, riflettendo la struttura localmente quadratica dell'approssimazione MM.*

Attenzione

Il parametro ε_{thr} controlla il trade-off tra sparsità della soluzione e stabilità numerica. Valori troppo piccoli ($\varepsilon_{\text{thr}} \ll 10^{-10}$) possono rendere A_k male condizionata e causare instabilità numerica. Valori troppo grandi smussano eccessivamente il termine L1 e riducono la sparsità della soluzione.

1.3 Algoritmo A2: Deflected Subgradient

Il deflected subgradient affronta il problema LASSO (1.1) direttamente nella sua forma non-smooth. L'idea è *mescolare il subgradiente corrente con la direzione precedente* (analogamente al Gradiente Coniugato nel caso smooth) per ottenere una direzione di discesa più informata.

1.3.1 Subgradiente del problema LASSO

Il subgradiente di $f(w) = \|Xw - y\|^2 + \lambda\|w\|_1$ è:

$$g^i \in \partial f(w^i) = 2X^\top(Xw^i - y) + \lambda s^i, \quad s^i \in \partial\|w^i\|_1, \quad [s^i]_j = \begin{cases} \text{sign}(w_j^i) & w_j^i \neq 0 \\ \text{qualsiasi in } [-1, 1] & w_j^i = 0 \end{cases}.$$

Complessità ottimale non-smooth (da [OPT/5, slide 8]):

Classe	Smoothness	Convessità	Complessità
$f \in C^1$	L -smooth	τ -forte	$O(\log 1/\varepsilon)$
$f \in C^1$	L -smooth	convexa	$O(1/\sqrt{\varepsilon})$
$f \notin C^1$	L -Lipschitz	τ -forte	$\Omega(L^2/\varepsilon)$
$f \notin C^1$	L -Lipschitz	convexa	$\Omega(L/\varepsilon^2)$

Il nostro $f = g + \lambda\|\cdot\|_1$ è non-smooth (L -Lipschitz convessa): il caso peggiore richiede $O(1/\varepsilon^2)$ iterazioni. Il deflected subgradient non migliora questo tasso asintotico, ma offre convergenza empiricamente più veloce.

1.3.2 Target level stepsize

Il passo fisso "non funziona" per funzioni non-smooth (il subgradiente non è una direzione di discesa garantita). Si usa lo **stepsize con target level** [OPT/5, slide 14]:

Algoritmo: Target Level Stepsize (SGPTL)

Parametri: $\beta \in (0, 2)$, $\delta_0 > 0$, $R > 0$, $\rho \in (0, 1)$.

1. $\text{fref} \leftarrow f(w^0)$; $\delta \leftarrow \delta_0$; $r \leftarrow 0$; $\bar{f} \leftarrow f(w^0)$.
2. Per $i = 1, 2, \dots$:
3. $g^i \in \partial f(w^i)$; $\alpha^i \leftarrow \beta(f^i - (\text{fref} - \delta))/\|g^i\|^2$;
4. $w^{i+1} \leftarrow w^i - \alpha^i g^i$.

5. Se $f(w^{i+1}) \leq \text{fref} - \delta/2$: $\text{fref} \leftarrow \bar{f}$; $r \leftarrow 0$.
6. Altrimenti se $r > R$: $\delta \leftarrow \delta \cdot \rho$; $r \leftarrow 0$.
7. Altrimenti: $r \leftarrow r + \alpha^i \|g^i\|$.
8. $\bar{f} \leftarrow \min(\bar{f}, f(w^{i+1}))$.

1.3.3 Deflection

Algoritmo: Deflected Subgradient (Algoritmo A2)

Dati $w^0, d^0 = -g^0 \in -\partial f(w^0)$; parametri target level.

1. Per $i = 1, 2, \dots$:
2. Calcola $g^i \in \partial f(w^i)$.
3. Calcola il *coefficiente di deflection* (formula chiusa):

$$\gamma^i = \arg \min_{\gamma \in [0,1]} \|\gamma g^i + (1-\gamma)d^{i-1}\|^2 = \max\left(0, \frac{(d^{i-1})^\top (d^{i-1} - g^i)}{\|g^i - d^{i-1}\|^2}\right),$$

con la convenzione $\gamma^i \in [0, 1]$.

4. Forma la *direzione deflessa*: $d^i = \gamma^i g^i + (1-\gamma^i)d^{i-1}$.
5. Calcola lo *stepsize* α^i (target level) con una delle due regole:
 - *Stepsize-restricted*: $\alpha^i = \beta^i (f^i - f_{\text{target}}) / \|d^i\|^2$, con $\beta^i \leq \gamma^i$.
 - *Deflection-restricted*: stepsize standard DSS o **Polyak**, con $\gamma^i \leq \alpha^{i-1} \|d^{i-1}\|^2 / (f^i - f^* + \alpha^{i-1} \|d^{i-1}\|^2)$.
6. $w^{i+1} \leftarrow w^i - \alpha^i d^i$.
7. Aggiorna il record: $\bar{f}^i \leftarrow \min(\bar{f}^{i-1}, f(w^{i+1}))$.

Attenzione

Quando $\beta^i \rightarrow 0$, si ha $d^i \rightarrow -\nabla f(w^i)$ (il deflected subgradient degenera nel subgradiente standard) — *convergenza lenta*. La deflection è utile *solo se* si mantiene γ^i significativo, il che richiede che i parametri siano calibrati con cura.

Teorema 1.2 (Convergenza del Deflected Subgradient, d’Antonio–Frangioni 2009). *Sotto le regole stepsize-restricted o deflection-restricted e con il target level stepsize, la sequenza $\{\bar{f}^i\}$ converge al valore ottimo f^* . Il tasso di convergenza è $O(1/\sqrt{k})$ (record value), con complessità $O(1/\varepsilon^2)$ nel caso peggiore.*

1.4 Confronto A1 vs A2

	A1 (IRLS)	A2 (Deflected Subgradient)
Approccio	Smooth (surrogate)	Non-smooth diretto
Costo/iterazione	Alto: $O(n^3)$ (Chol.) o $O(kn^2)$ (CG)	Basso: $O(mn)$
Num. iterazioni	Poche (10–50)	Molte (migliaia)
Convergenza	Tipicamente lineare	Sublineare $O(1/\varepsilon^2)$
Alta precisione	Sì ($\varepsilon < 10^{-8}$)	Difficile ($\varepsilon < 10^{-4}$)
Parametri	ε_{thr} , solver lineare	$\delta_0, \rho, R, \beta, \gamma$

Quando usare quale

IRLS è preferibile quando si richiede alta **precisione** ($\varepsilon < 10^{-6}$). **A2** può essere **competitivo in tempo CPU per soluzioni a bassa precisione** ($\varepsilon \sim 10^{-2}$), **specialmente per n molto grande dove Cholesky diventa proibitivo**.

Capitolo 2

Ottimizzazione Non Vincolata — Metodi non-smooth

2.1 Funzioni non differenziabili

Molte funzioni nel ML **non sono differenziabili ovunque**:

- $f(x) = \|x\|_1 = \sum_i |x_i|$ (**LASSO**, sparsità, compressive sensing).
- $f(x) = \max_j g_j(x)$ (**SVM**, ottimizzazione worst-case).
- $f(x) = \max(0, x)$ (**ReLU**, attivazione neurale).

Definizione 2.1 (Subgradiente). $g \in \mathbb{R}^n$ è un **subgradiente** di f convessa in x se:

$$f(y) \geq f(x) + g^\top (y - x) \quad \forall y.$$

L'**insieme** dei subgradienti $\partial f(x)$ è detto **subdifferenziale**.

Esempio 2.1. Per $f(x) = |x|$: $\partial f(x) = \{+1\}$ se $x > 0$, $[-1, +1]$ se $x = 0$, $\{-1\}$ se $x < 0$. Per $f(x) = \|x\|_1$: $[\partial f(x)]_i = \text{sign}(x_i)$ se $x_i \neq 0$, e $\in [-1, +1]$ se $x_i = 0$.

Teorema 2.1. x^* è un minimo globale di f convessa $\Leftrightarrow 0 \in \partial f(x^*)$.

2.2 Metodo del subgradiente

Algoritmo: Subgradient Method

Dato x_0 , step sizes $\{\alpha_k\}$:

$$x_{k+1} = x_k - \alpha_k g_k, \quad g_k \in \partial f(x_k).$$

Attenzione

A differenza del gradient descent, **il subgradiente non garantisce $f(x_{k+1}) < f(x_k)$** : **l'obiettivo può aumentare da un'iterazione all'altra**. Si usa il **record del best so far**:

$$f_k^{\text{best}} = \min_{i < k} f(x_i).$$

Teorema 2.2 (Convergenza del subgradiente). *Se f convessa, Lipschitz con costante G :*

- Con $\alpha_k = c/\sqrt{k}$ (diminishing): $f_k^{\text{best}} - f^* \leq \frac{G\|x_0 - x^*\|}{\sqrt{k}}$ (tasso $O(1/\sqrt{k})$).
- Con $\alpha_k = c$ costante: $\liminf f_k^{\text{best}} \leq f^* + Gc/2$.

Osservazione 2.1. Il tasso $O(1/\sqrt{k})$ è ottimale per metodi del primo ordine su funzioni Lipschitz non smooth. Per funzioni smooth, si può fare meglio: $O(1/k)$ con GD.

2.3 Metodo del gradiente prossimale

Molte funzioni hanno la forma $f(x) = h(x) + r(x)$, con h smooth e r non-smooth ma semplice (es. $r(x) = \lambda\|x\|_1$).

Definizione 2.2 (Operatore prossimale). Per $r : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ e $\alpha > 0$:

$$\text{prox}_{\alpha r}(v) = \arg \min_x \left(r(x) + \frac{1}{2\alpha} \|x - v\|^2 \right).$$

Esempio 2.2 (Prox dell' ℓ^1 : soft thresholding). Per $r(x) = \lambda\|x\|_1$:

$$[\text{prox}_{\alpha\lambda\|\cdot\|_1}(v)]_i = \text{sign}(v_i) \max(|v_i| - \alpha\lambda, 0).$$

Questa è la *sogliatura morbida* (soft thresholding).

Algoritmo: Proximal Gradient (ISTA)

Per $f = h + r$ con h L -smooth, r convessa:

$$x_{k+1} = \text{prox}_{\alpha r}(x_k - \alpha \nabla h(x_k)), \quad \alpha = 1/L.$$

Teorema 2.3 (Convergenza ISTA). Con $\alpha = 1/L$: $f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|^2}{2k}$ (tasso $O(1/k)$).

Osservazione 2.2 (FISTA — accelerazione di Nesterov). FISTA (Fast ISTA) aggiunge un passo di momento come Nesterov e raggiunge $O(1/k^2)$, ottimale per la classe. È il metodo standard per LASSO di grande scala.

2.4 Metodi bundle

I metodi bundle sono la generalizzazione dei metodi del gradiente coniugato per funzioni non-smooth.

Definizione 2.3 (Modello bundle (piecewise-linear inferior)). Dati gli iterati precedenti $x^1, \dots, x^i$ con subgradienti $g^j \in \partial f(x^j)$, il bundle è:

$$f_B(x) = \max_{j \leq i} \left\{ f(x^j) + (g^j)^\top (x - x^j) \right\} \leq f(x).$$

f_B è un modello inferiore di f .

Algoritmo: Bundle Method (schema generale)

Dati x_0 , parametro di prossimità $\mu > 0$:

1. Risolvi: $d^* = \arg \min_d \{f_B(x_k + d) + \frac{\mu}{2} \|d\|^2\}$,
2. Se $\|d^*\| \leq \varepsilon$: STOP (criterio di ottimalità).
3. Valuta $f(x_k + d^*)$ e $g^* \in \partial f(x_k + d^*)$.
4. **Serious step**: se $f(x_k + d^*) \leq f(x_k) - m_1(f_B(x_k + d^*) - f(x_k))$: $x_{k+1} \leftarrow x_k + d^*$.
5. **Null step**: altrimenti $x_{k+1} \leftarrow x_k$. Aggiorna il bundle con il nuovo punto.

Teorema 2.4 (Convergenza dei metodi bundle). Per f convessa Lipschitz, con μ fisso e bounded: se $f^* > -\infty$, allora $\|d_i^*\| \rightarrow 0$, il che implica la convergenza all'ottimo.

Parte II

Livello 2 — Intorno Ottimizzazione (Esame Orale)

Capitolo 3

Ottimizzazione Non Vincolata

3.1 Richiami di analisi in più variabili

3.1.1 Gradiente, Hessiana, sviluppo di Taylor

Definizione 3.1 (Gradiente). Per $f : \mathbb{R}^n \rightarrow \mathbb{R}$ differenziabile:

$$\nabla f(x) = \left(\frac{\partial f}{\partial x_1}, \dots, \frac{\partial f}{\partial x_n} \right)^\top \in \mathbb{R}^n.$$

$\nabla f(x)$ punta nella direzione di massima crescita di f in x .

Definizione 3.2 (Hessiana). Per $f \in C^2(\mathbb{R}^n)$:

$$\nabla^2 f(x) = H_f(x) \in \mathbb{R}^{n \times n}, \quad [H_f(x)]_{ij} = \frac{\partial^2 f}{\partial x_i \partial x_j}(x).$$

Per il teorema di Schwarz, H_f è simmetrica.

Sviluppo di Taylor al secondo ordine:

$$f(x+d) = f(x) + \nabla f(x)^\top d + \frac{1}{2} d^\top H_f(x) d + o(\|d\|^2).$$

Esempio 3.1 (Funzione quadratica). $f(x) = \frac{1}{2} x^\top Q x - c^\top x$ con Q simmetrica: $\nabla f(x) = Qx - c$, $H_f(x) = Q$ (costante).

3.1.2 Condizioni di ottimalità

Teorema 3.1 (Condizioni del primo e secondo ordine). Per $f \in C^2$:

1. **Necessaria 1° ordine:** Se x^* è minimo locale, $\nabla f(x^*) = 0$ (punto stazionario).
2. **Necessaria 2° ordine:** Se x^* è minimo locale, $H_f(x^*) \succeq 0$.
3. **Sufficiente:** Se $\nabla f(x^*) = 0$ e $H_f(x^*) \succ 0$, allora x^* è minimo locale isolato.

3.1.3 Classi di regolarità importanti

Definizione 3.3 (L -smooth). $f \in C^1$ è L -smooth se ∇f è Lipschitz con costante $L > 0$:

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\| \quad \forall x, y.$$

Equivalentemente (per $f \in C^2$): $\nabla^2 f(x) \preceq LI$ per ogni x .

Proposizione 3.1 (Lemma di discesa). Se f è L -smooth, allora per ogni x, d :

$$f(x + d) \leq f(x) + \nabla f(x)^\top d + \frac{L}{2}\|d\|^2.$$

Questo è il modello quadratico superiore di f .

Definizione 3.4 (τ -strongly convex). f è fortemente convessa con modulo $\tau > 0$ se:

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{\tau}{2}\|y - x\|^2 \quad \forall x, y.$$

Equivalentemente: $\nabla^2 f(x) \succeq \tau I$, cioè tutti gli autovalori dell'Hessiana sono $\geq \tau$.

Osservazione 3.1. La classe “più conveniente” per l'ottimizzazione è f L -smooth e τ -fortemente convessa, con $\kappa = L/\tau$ (numero di condizionamento dell'ottimizzazione). Se $\kappa \gg 1$, il problema è *difficile*.

3.1.4 Funzioni convesse

Definizione 3.5 (Funzione convessa). f è convessa se per ogni x, y e $\lambda \in [0, 1]$:

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y).$$

Proposizione 3.2 (Caratterizzazioni equivalenti per $f \in C^2$). Le seguenti sono equivalenti:

(a) f convessa; (b) $f(y) \geq f(x) + \nabla f(x)^\top (y - x)$ (disuguaglianza del gradiente); (c) $H_f(x) \succeq 0$ per ogni x .

Teorema 3.2 (Ottimalità globale). Se f è convessa, ogni minimo locale è globale. Se f è strettamente convessa, il minimizzatore è unico.

3.2 Metodi del gradiente (smooth)

3.2.1 Gradient Descent a passo fisso

Algoritmo: Gradient Descent

Dato $x_0 \in \mathbb{R}^n$, step size $\alpha > 0$:

$$x_{k+1} = x_k - \alpha \nabla f(x_k), \quad k = 0, 1, 2, \dots$$

Intuizione 3.1. $-\nabla f(x_k)$ è la direzione di massima discesa. Muoversi di un passo α in tale direzione riduce f di $\alpha\|\nabla f(x_k)\|^2$ (approssimativamente), se α è abbastanza piccolo.

3.2.1.1 Convergenza per funzioni quadratiche

Teorema 3.3 (Convergenza GD per f quadratica $Q \succ 0$). Sia $f(x) = \frac{1}{2}x^\top Qx - c^\top x$ con $0 < \lambda_{\min} = \lambda_n \leq \lambda_1 = \lambda_{\max}$ autovalori di Q . Con passo ottimo $\alpha^* = \frac{2}{\lambda_{\min} + \lambda_{\max}}$:

$$\|x_k - x^*\|_Q \leq \left(\frac{\kappa(Q) - 1}{\kappa(Q) + 1} \right)^k \|x_0 - x^*\|_Q,$$

dove $\kappa(Q) = \lambda_{\max}/\lambda_{\min}$ e $\|v\|_Q^2 = v^\top Qv$.

Osservazione 3.2 (Disuguaglianza di Kantorovich). Nell'analisi di convergenza, la chiave è la *disuguaglianza di Kantorovich*:

$$\frac{(g^\top g)^2}{(g^\top Qg)(g^\top Q^{-1}g)} \geq \frac{4\lambda_{\min}\lambda_{\max}}{(\lambda_{\min} + \lambda_{\max})^2} = 1 - \left(\frac{\kappa - 1}{\kappa + 1} \right)^2.$$

Essa misura quanto la curvatura non uniforme di f rallenti la discesa.

3.2.1.2 Convergenza per funzioni smooth convesse

Teorema 3.4 (GD con passo $1/L$: convergenza $O(1/k)$). Sia f *convessa* e *L -smooth*. Con $\alpha = 1/L$:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|^2}{2k}.$$

Prova (sketch): Dal lemma di discesa con $\alpha = 1/L$:

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2.$$

Sommando k passi e usando la disuguaglianza del gradiente, si ottiene la tesi.

Teorema 3.5 (GD per funzioni fortemente convesse: convergenza lineare). Se f è *L -smooth* e *τ -fortemente convessa*, con $\alpha = 1/L$:

$$\|x_k - x^*\|^2 \leq \left(1 - \frac{\tau}{L} \right)^k \|x_0 - x^*\|^2 = \left(1 - \frac{1}{\kappa} \right)^k \|x_0 - x^*\|^2.$$

La convergenza è *lineare* (geometrica) con fattore $\rho = 1 - 1/\kappa$.

Osservazione 3.3 (Confronto tra i tassi). $O(1/k)$ (convex) vs $O(\rho^k)$ (strongly convex): il secondo è *esponenzialmente* più veloce. Tuttavia, per κ grande, anche la convergenza lineare è molto lenta ($\rho \approx 1 - 1/\kappa$ piccolo).

3.2.1.3 Metodi con momento: Nesterov

Il metodo di Nesterov (1983) aggiunge un termine di “inerzia”:

$$y_{k+1} = x_k - \frac{1}{L} \nabla f(x_k), \quad x_{k+1} = y_{k+1} + \frac{k-1}{k+2} (y_{k+1} - y_k).$$

Converge come $O(L/k^2)$ invece di $O(L/k)$: *optimal* per la classe dei metodi del primo ordine. Il termine di momento riutilizza la direzione dell'iterazione precedente.

3.2.2 Line Search adattiva

3.2.2.1 Condizioni di Armijo e Wolfe

Definizione 3.6 (Condizione di **Armijo** (sufficient decrease)). Con direzione di discesa d_k e step $\alpha > 0$:

$$f(x_k + \alpha d_k) \leq f(x_k) + c_1 \alpha \nabla f(x_k)^\top d_k, \quad c_1 \in (0, 1).$$

Definizione 3.7 (Condizione di curvatura (Wolfe)).

$$\nabla f(x_k + \alpha d_k)^\top d_k \geq c_2 \nabla f(x_k)^\top d_k, \quad c_2 \in (c_1, 1).$$

Algoritmo: Backtracking Armijo

1. $\alpha \leftarrow \alpha_0$ (es. $\alpha_0 = 1$), $\rho \in (0, 1)$ (es. $\rho = 0.5$).
2. **Finché** Armijo non è soddisfatta: $\alpha \leftarrow \rho \alpha$.
3. Usa α per il passo $x_{k+1} = x_k + \alpha d_k$.

Teorema 3.6 (Convergenza GD con Armijo). Se f è **L -smooth e inferiormente limitata**, e si usa **backtracking Armijo**, allora $\|\nabla f(x_k)\| \rightarrow 0$.

Osservazione 3.4 (Line search esatta per quadratiche). Per $f(x) = \frac{1}{2}x^\top Qx - c^\top x$, $g_k = Qx_k - c$:

$$\alpha_k^* = \arg \min_{\alpha \geq 0} f(x_k - \alpha g_k) = \frac{g_k^\top g_k}{g_k^\top Q g_k}.$$

3.3 Metodo di Newton multivariato

Algoritmo: Metodo di Newton

Dato x_0 , per $k = 0, 1, \dots$:

$$H_f(x_k)d_k = -\nabla f(x_k), \quad x_{k+1} = x_k + d_k.$$

(con eventuale line search: $x_{k+1} = x_k + \alpha_k d_k$)

Intuizione 3.2. Newton *minimizza il modello quadratico locale* di f :

$$m_k(d) = f(x_k) + \nabla f(x_k)^\top d + \frac{1}{2}d^\top H_f(x_k)d.$$

Il minimo di m_k (se $H_f \succ 0$) è esattamente $d_k = -H_f^{-1}\nabla f$.

Teorema 3.7 (Convergenza quadratica locale). Se $f \in C^3$, x^* è un minimo con $H_f(x^*) \succ 0$, e x_0 è sufficientemente vicino a x^* :

$$\|x_{k+1} - x^*\| \leq C \|x_k - x^*\|^2$$

per una costante $C > 0$ che dipende da $\|\nabla^3 f\|$ e da $\lambda_{\min}(H_f(x^*))$.

Limitazioni: Costo $O(n^3)$ per passo (fattorizzazione di H_f); H_f potrebbe non essere $\succ 0$ lontano da x^* ; non globalmente convergente senza modifiche.

Modifiche pratiche:

- **Damped Newton:** $x_{k+1} = x_k + \alpha_k d_k$ con line search su α_k .
- **Regularized Newton:** $H_f(x_k) + \mu_k I$ con $\mu_k > 0$ (connessione con trust-region).
- **Inexact Newton:** risolvere il sistema $H_f d = -\nabla f$ approssimativamente (es. con CG).

3.4 Metodi quasi-Newton

Idea: approssimare H_f^{-1} tramite aggiornamenti di rango basso, usando solo informazioni sul gradiente.

Definizione 3.8 (Condizione secante). Dati $s_k = x_{k+1} - x_k$ e $y_k = \nabla f(x_{k+1}) - \nabla f(x_k)$, si vuole $B_{k+1}s_k = y_k$ (approssimazione $B_{k+1} \approx H_f$).

3.4.1 Aggiornamento BFGS

L'aggiornamento **BFGS** (Broyden–Fletcher–Goldfarb–Shanno), con $H_k \approx H_f^{-1}(x_k)$:

$$H_{k+1} = \left(I - \rho_k s_k y_k^\top\right) H_k \left(I - \rho_k y_k s_k^\top\right) + \rho_k s_k s_k^\top, \quad \rho_k = \frac{1}{y_k^\top s_k}. \quad (3.1)$$

Proposizione 3.3 (Proprietà BFGS). 1. Se $H_k \succ 0$ e $y_k^\top s_k > 0$ (garantito da Wolfe), allora $H_{k+1} \succ 0$.

2. $H_{k+1}s_k = s_k / (y_k^\top s_k) \cdot (y_k^\top s_k) = s_k \dots$ ovvero $H_{k+1}y_k = s_k$ (condizione secante).

3. BFGS è l'aggiornamento di minima perturbazione (in norma di Frobenius pesata) che soddisfa la condizione secante.

Teorema 3.8 (Convergenza superlineare di BFGS). Sotto ipotesi di regolarità standard (f L -smooth, τ -strongly convex), BFGS ha **convergenza superlineare**:

$$\|x_{k+1} - x^*\| = o(\|x_k - x^*\|).$$

Osservazione 3.5 (L-BFGS per grande scala). L-BFGS (Limited-memory BFGS) memorizza solo le ultime m coppie (s_k, y_k) per ricostruire H_k^{-1} implicitamente. Costo $O(mn)$ per passo (anziché $O(n^2)$ per BFGS pieno). Fondamentale per ML: addestramento di reti neurali, ottimizzazione su $n = 10^7$ parametri.

3.5 Gradiente Coniugato per funzioni quadratiche

Il metodo del *gradiente coniugato* (CG) **minimizza** $f(x) = \frac{1}{2}x^\top Qx - c^\top x$ con $Q \succ 0$, equivalente a risolvere $Qx = c$.

Definizione 3.9 (Q -coniugazione). Vettori $d_0, d_1, \dots$ sono Q -coniugati se $d_i^\top Q d_j = 0$ per $i \neq j$.

Algoritmo: Gradiente Coniugato (CG)

x_0 dato, $r_0 = c - Qx_0$, $d_0 = r_0$. Per $k = 0, 1, \dots$:

$$\begin{aligned} \alpha_k &= \frac{r_k^\top r_k}{d_k^\top Q d_k}, & x_{k+1} &= x_k + \alpha_k d_k, \\ r_{k+1} &= r_k - \alpha_k Q d_k, & \beta_{k+1} &= \frac{r_{k+1}^\top r_{k+1}}{r_k^\top r_k}, \\ d_{k+1} &= r_{k+1} + \beta_{k+1} d_k. \end{aligned}$$

Teorema 3.9 (Ottimalità di CG). Dopo k passi, x_k minimizza f sullo spazio di Krylov

$$\mathcal{K}_k(Q, r_0) = \text{span}(r_0, Qr_0, \dots, Q^{k-1}r_0).$$

CG converge in al più n passi (terminazione esatta).

Teorema 3.10 (Convergenza lineare di CG).

$$\frac{\|x_k - x^*\|_Q}{\|x_0 - x^*\|_Q} \leq 2 \left(\frac{\sqrt{\kappa(Q)} - 1}{\sqrt{\kappa(Q)} + 1} \right)^k.$$

CG è molto più veloce del gradient descent: il fattore è $\sqrt{\kappa}$ anziché κ .

Intuizione 3.3. CG minimizza il residuo relativo su uno spazio polinomiale: trova il polinomio p_k di grado $\leq k$ con $p_k(0) = 1$ che minimizza $\max_{\lambda_i} |p_k(\lambda_i)|$. Se gli autovalori di Q sono raggruppati in m cluster, CG converge in m passi.

3.6 Metodi del gradiente deflesso (smooth)

Il concetto di *deflection* nel caso smooth precede e motiva l'Algoritmo A2 del progetto. L'idea è mescolare il gradiente corrente $-\nabla f(x^i)$ con la direzione precedente d^{i-1} :

$$d^i = -\nabla f(x^i) + \beta^i d^{i-1}, \quad x^{i+1} = x^i + \alpha^i d^i,$$

NCG (Nonlinear Conjugate Gradient) — quattro formule per β^i :

- **Fletcher-Reeves**: $\beta^i = \|\nabla f(x^i)\|^2 / \|\nabla f(x^{i-1})\|^2$.
- **Polak-Ribière**: $\beta^i = \nabla f(x^i)^\top (\nabla f(x^i) - \nabla f(x^{i-1})) / \|\nabla f(x^{i-1})\|^2$.
- **Hestenes-Stiefel**: $\beta^i = \nabla f(x^i)^\top y^i / (d^{i-1})^\top y^i$, $y^i = \nabla f(x^i) - \nabla f(x^{i-1})$.
- **Dai-Yuan**: $\beta^i = \|\nabla f(x^i)\|^2 / (d^{i-1})^\top y^i$.

Heavy Ball: usa la formula $d^i = -\nabla f(x^i) + \beta d^{i-1}$ con β fisso. Per funzioni fortemente convesse con costanti τ, L : tasso di convergenza $r = (\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$, lo stesso del CG lineare.

Osservazione 3.6 (Analogia con A2). Il Deflected Subgradient (Algoritmo A2) applica la stessa idea al caso non-smooth: sostituisce ∇f con $g^i \in \partial f(x^i)$ e usa regole di deflection e stepsize più complesse per garantire la convergenza. La deflection smooth riduce il numero di condizione efficace; la deflection non-smooth riduce l'oscillazione dovuta alla scelta del subgradiente.

Parte III

Livello 3 — Core NLA del Progetto

Capitolo 4

Il Problema dei Minimi Quadrati

4.1 Formulazione

Definizione 4.1 (Least Squares). Dato $A \in \mathbb{R}^{m \times n}$ ($m \geq n$), $b \in \mathbb{R}^m$:

$$\min_{x \in \mathbb{R}^n} \|Ax - b\|_2^2.$$

Se $m > n$, il sistema $Ax = b$ è sovradeterminato (più equazioni che incognite) — in generale non ha soluzione esatta.

Teorema 4.1 (Soluzione geometrica). x^* è soluzione LS $\Leftrightarrow$ il residuo $r^* = Ax^* - b$ è ortogonale a $\text{Im}(A)$, cioè $A^\top(Ax^* - b) = 0$.

Intuizione 4.1. Ax^* è la proiezione ortogonale di b su $\text{Im}(A)$. Il punto più vicino a b nell'immagine di A si trova proiettando.

4.2 Equazioni normali

Teorema 4.2 (Equazioni normali). x^* è soluzione LS $\Leftrightarrow$ soddisfa le equazioni normali:

$$A^\top Ax^* = A^\top b.$$

Se A ha rango massimo ($\text{rank } A = n$, cioè $A^\top A \succ 0$), la soluzione è unica: $x^* = (A^\top A)^{-1} A^\top b$.

4.3 Soluzione via SVD

Dalla thin SVD $A = \hat{U}\Sigma V^\top$, la soluzione di norma minima è:

$$x^* = A^+ b = V \Sigma^+ \hat{U}^\top b = \sum_{i=1}^r \frac{\hat{u}_i^\top b}{\sigma_i} v_i.$$

Osservazione 4.1 (Valori singolari piccoli e regolarizzazione). Se A ha valori singolari piccoli, la soluzione x^* è amplificata enormemente. La regolarizzazione di Tikhonov (ridge regression)

modifica il problema:

$$\min_x \|Ax - b\|^2 + \delta \|x\|^2 \quad \Rightarrow \quad x_\delta = (A^\top A + \delta I)^{-1} A^\top b = V \operatorname{diag}\left(\frac{\sigma_i}{\sigma_i^2 + \delta}\right) \hat{U}^\top b.$$

Per $\delta > 0$, i valori singolari piccoli vengono smorzati: $\sigma_i/(\sigma_i^2 + \delta) \approx 1/\delta$ se $\sigma_i \ll \sqrt{\delta}$.

Capitolo 5

Fattorizzazioni Dirette per Sistemi Lineari

5.1 Fattorizzazione LU

Teorema 5.1 (LU con pivoting parziale). Per ogni $A \in \mathbb{R}^{n \times n}$, con un'opportuna matrice di permutazione P :

$$PA = LU,$$

con L triangolare inferiore con diagonale unitaria ($|L_{ij}| \leq 1$), U triangolare superiore. **Costo:** $\frac{2}{3}n^3$ flop.

Intuizione 5.1. LU è la fattorizzazione dell'eliminazione gaussiana. Il pivoting parziale (scegliere il pivot come l'elemento di modulo massimo nella colonna corrente) garantisce la **stabilità numerica**: $|L_{ij}| \leq 1$ previene la crescita degli errori di arrotondamento.

Algoritmo: Risoluzione via LU

Per $Ax = b$ con $PA = LU$:

1. Permuta: $\tilde{b} = Pb$.
2. Forward substitution: $Ly = \tilde{b}$, $O(n^2)$.
3. Back substitution: $Ux = y$, $O(n^2)$.

Costo totale: $\frac{2}{3}n^3$ (fattorizzazione) + $2n^2$ (soluzione). Stessa fattorizzazione per più termini noti.

Teorema 5.2 (Backward stability di LU con pivoting). **LU con pivoting parziale è backward stable**: $\tilde{L}\tilde{U} = PA + E$ con $\|E\| = O(u\|A\|)$ (tipicamente — casi patologici esistono ma sono rari in pratica).

5.2 Fattorizzazione $LDL^\top$ per matrici simmetriche

Per $M = M^\top$, l'eliminazione simmetrica produce $M = LDL^\top$: costo $\frac{1}{3}n^3$ (metà di LU pieno sfruttando la simmetria). Il pivoting di Bunch-Kaufman usa blocchi 1×1 e 2×2 in D per stabilità.

5.3 Fattorizzazione di Cholesky

Teorema 5.3 (Cholesky). Se $M = M^\top \succ 0$, esiste un'unica R triangolare superiore con diagonale positiva tale che $M = R^\top R$. **Costo:** $\frac{1}{3}n^3$ — metà di LU!

Proposizione 5.1. $M \succ 0 \Leftrightarrow$ tutti i pivot dell'eliminazione di Cholesky sono positivi. Quindi Cholesky può servire come test di definitezza positiva (se fallisce, $M \not\succ 0$).

Algoritmo: Risoluzione con Cholesky

Per $Mx = b$ con $M \succ 0$:

1. Calcola $R = \text{chol}(M)$, $\frac{1}{3}n^3$.
2. Forward: $R^\top y = b$, $O(n^2)$.
3. Back: $Rx = y$, $O(n^2)$.

5.4 Confronto e scelta dell'algoritmo

Struttura di A	Algoritmo	Costo	Backward stable
Quadrata generica	LU + pivoting parz.	$\frac{2}{3}n^3$	Sì (praticamente)
Simmetrica	$LDL^\top$ (Bunch-K.)	$\frac{1}{3}n^3$	Sì
SPD	Cholesky	$\frac{1}{3}n^3$	Sì (no pivoting!)
LS, $m \geq n$	QR (Householder)	$2mn^2 - \frac{2}{3}n^3$	Sì
SPD sparsa	CG (precondizionato)	$O(k \cdot \text{nnz})$	—
Generale sparsa	GMRES (precond.)	$O(k \cdot \text{nnz})$	—

Osservazione 5.1 (Regola pratica). Per sistemi **densi**: scegliere in base alla **struttura** (Cholesky se SPD, LU altrimenti). Per sistemi **sparsi** di **grande scala** ($n > 10^4$): usare **CG** (se SPD) o **GMRES** (altrimenti) con un buon preconditionatore. Non usare mai $\text{inv}(A)$.

5.5 Esempi pratici

Esempio 5.1 (Riordino per ridurre il fill-in). Per matrici sparse, LU/Cholesky può produrre fattori molto più densi (*fill-in*). Riordinare con Cuthill-McKee (`symrcm` in Matlab) riduce l'ampiezza di banda.

```
1 p = symrcm(A);
2 R = chol(A(p, p));           % Cholesky riordinato
3 x_perm = R \ (R' \ b(p));
4 x(p) = x_perm;              % permutazione inversa
```

Esempio 5.2 (Tikhonov via SVD in Python).

```
1 import numpy as np
2 U, s, Vt = np.linalg.svd(A, full_matrices=False)
3 delta = 1e-4
4 d = s / (s**2 + delta)      # filtro di Tikhonov
5 x = Vt.T @ (d * (U.T @ b)) # soluzione regolarizzata
```


Capitolo 6

Metodi Iterativi per Sistemi Lineari

6.1 Motivazione: sistemi sparsi di grande scala

Per $n = 10^5$ - 10^7 : LU richiede $O(n^3) \gg 10^{15}$ flop — completamente impraticabile. Ma spesso la matrice è *sparsa*: $\text{nnz}(A) \ll n^2$ (es. $O(n)$ nonzeri per riga). Il prodotto Av ha allora costo $O(\text{nnz}(A))$.

I *metodi iterativi di Krylov* sfruttano questa struttura: ogni passo richiede solo un prodotto matrice-vettore.

6.2 Spazi di Krylov

Definizione 6.1. $\mathcal{K}_k(A, b) = \text{span}(b, Ab, A^2b, \dots, A^{k-1}b) \subseteq \mathbb{R}^n$.

Proposizione 6.1. $x_k = q_{k-1}(A)b$ per qualche polinomio q_{k-1} di grado $\leq k-1$. I metodi di Krylov scelgono q_{k-1} in modo ottimale rispetto a qualche criterio.

6.3 Gradiente Coniugato per sistemi SPD

CG (già visto nell'ottimizzazione) risolve $Qx = v$ con $Q \succ 0$:

Teorema 6.1 (Convergenza CG).

$$\frac{\|x_k - x^*\|_Q}{\|x_0 - x^*\|_Q} \leq 2 \left(\frac{\sqrt{\kappa(Q)} - 1}{\sqrt{\kappa(Q)} + 1} \right)^k.$$

Se Q ha m autovalori distinti, CG converge in esattamente m passi. Per autovalori raggruppati (clustered), la convergenza è rapida: il polinomio di Chebyshev approssima bene la “forma” dello spettro.

6.3.1 Precondizionamento

Definizione 6.2 (Preconditioned CG). $P \approx Q$ invertibile, $P \succ 0$. Si risolve $P^{-1}Qx = P^{-1}v$, che ha lo stesso spettro “rimodellato”.

La convergenza dipende da $\kappa(P^{-1}Q) \ll \kappa(Q)$. Scelte comuni:

- $P = \text{diag}(Q)$ (Jacobi): semplice, smorzamento delle scale.
- $P =$ fattore di Cholesky incompleto (ICC): più efficace.
- $P = \text{ILUTP}$ per sistemi non simmetrici.

6.4 Algoritmo di Arnoldi

Per sistemi **non simmetrici**, si costruisce una base ortonormale di $\mathcal{K}_k(A, b)$ stabilmente.

Algoritmo: Arnoldi

$q_1 = b/\|b\|$. Per $j = 1, \dots, k$:

1. $w = Aq_j$.
2. Per $i = 1, \dots, j$: $h_{ij} = q_i^\top w$; $w \leftarrow w - h_{ij}q_i$ (ortogonalizzazione).
3. $h_{j+1,j} = \|w\|$; se $h_{j+1,j} = 0$: STOP (breakdown). Altrimenti $q_{j+1} = w/h_{j+1,j}$.

Teorema 6.2 (Fattorizzazione di Arnoldi). *Dopo k passi: $AQ_k = Q_{k+1}H_k$, dove:*

- $Q_k = [q_1, \dots, q_k] \in \mathbb{R}^{n \times k}$ ha **colonne ortonormali**.
- $H_k \in \mathbb{R}^{(k+1) \times k}$ è una matrice di **Hessenberg superiore**.

Intuizione 6.1. Arnoldi è Gram-Schmidt applicato alle potenze di A : costruisce una base ortogonale senza formare esplicitamente $[b, Ab, \dots, A^{k-1}b]$ (che sarebbero numericamente instabili per potenze elevate).

Osservazione 6.1 (Caso simmetrico: Lanczos). Se $A = A^\top$, la matrice H_k è simmetrica tridiagonale. L'algoritmo si semplifica nella ricorrenza di Lanczos: ogni passo richiede solo 2 prodotti matrice-vettore e la memorizzazione di 3 vettori (invece di k per Arnoldi). Si ricade nel metodo CG per sistemi SPD.

6.5 GMRES

Definizione 6.3 (GMRES — Generalized Minimal Residual). **Al passo k , GMRES trova la migliore approssimazione nello spazio di Krylov rispetto al residuo:**

$$x_k = \arg \min_{x \in x_0 + \mathcal{K}_k(A, r_0)} \|Ax - b\|.$$

Algoritmo: GMRES

1. Esegui k passi di Arnoldi su (A, r_0) : ottieni Q_{k+1}, H_k .
2. Nota che $r_k = Ax_k - b = Q_{k+1}(H_k z_k - \|r_0\|e_1)$ con $x_k = x_0 + Q_k z_k$.
3. Risolvi il piccolo problema LS: $z_k = \arg \min_z \|H_k z - \|r_0\|e_1\|$ (costo $O(k^2)$).

4. Soluzione: $x_k = x_0 + Q_k z_k$.

Il residuo si calcola come by-product dalla fattorizzazione QR di H_k (aggiornata a ogni passo).

Teorema 6.3 (Convergenza GMRES). *Se $A = V\Lambda V^{-1}$ (diagonalizzabile), allora:*

$$\frac{\|r_k\|}{\|r_0\|} \leq \kappa(V) \min_{p \in \mathcal{P}_k, p(0)=1} \max_{\lambda_i} |p(\lambda_i)|,$$

dove $\mathcal{P}_k$ è l'insieme dei polinomi di grado $\leq k$. Il termine $\kappa(V)$ misura quanto A “non è normale”.

Intuizione 6.2. GMRES converge rapidamente se gli autovalori di A sono raggruppati in pochi cluster: il polinomio ottimale può essere piccolo su tutti gli autovalori con poche “radici” (una per cluster). Se A ha autovalori ben separati, la convergenza è lenta.

Breakdown fortunato: se $\|w\| = 0$ in Arnoldi, allora $Ax = b$ ha una soluzione esatta nel Krylov — GMRES ha trovato la soluzione!

Attenzione

GMRES ha costo crescente per iterazione: $O(k^2)$ per la fattorizzazione QR di H_k e $O(kn)$ per lo storage. Si usa *restarted GMRES*: dopo m passi si ricomincia da x_m . Il costo diventa $O(mn)$ per ciclo, ma la convergenza può rallentare.

Parte IV

Livello 4 — Intorno NLA (Esame Orale)

Capitolo 7

Condizionamento e Stabilità

7.1 Numero di condizionamento

Definizione 7.1 (Numero di condizionamento assoluto e relativo). Per $f : \mathbb{R}^m \rightarrow \mathbb{R}^n$:

$$\kappa_{\text{abs}}(f, x) = \lim_{\delta \rightarrow 0} \sup_{\|d\| \leq \delta} \frac{\|f(x+d) - f(x)\|}{\|d\|}, \quad \kappa_{\text{rel}}(f, x) = \kappa_{\text{abs}} \cdot \frac{\|x\|}{\|f(x)\|}.$$

Teorema 7.1 (Numero di condizionamento di un sistema lineare). Per $f(b) = A^{-1}b$ (risolvere $Ax = b$):

$$\kappa(A) = \|A\| \cdot \|A^{-1}\| = \frac{\sigma_1}{\sigma_n}.$$

Perturbando b di δb : $\frac{\|\delta x\|}{\|x\|} \leq \kappa(A) \frac{\|\delta b\|}{\|b\|}$.

Intuizione 7.1. $\kappa(A) \gg 1$: problema *mal condizionato*. Se $\kappa(A) = 10^6$ e b ha un errore relativo di 10^{-12} (precisione di macchina), la soluzione x ha un errore relativo di $\approx 10^{-6}$: si perdono 6 cifre decimali.

Proposizione 7.1 (Distanza dalla singolarità). $1/\kappa(A) = \min_{\tilde{A} \text{ singolare}} \|\tilde{A} - A\|/\|A\|$. *Matrici con $\kappa(A) \gg 1$ sono “quasi singolari”.*

Teorema 7.2 (Condizionamento del problema LS). Per $\min_x \|Ax - b\|$ con A a rango massimo e soluzione x^* :

- Perturbazione di b : errore relativo proporzionale a $\kappa(A)$.
- Perturbazione di A : errore proporzionale a $\kappa(A)^2$ se $\|r^*\|/\|b\|$ non è trascurabile.

Nota: $\kappa(A^\top A) = \kappa(A)^2$, confermando l'instabilità delle equazioni normali.

7.2 Aritmetica floating point

I numeri double-precision (IEEE 754, 64 bit) hanno struttura:

$$\underbrace{1 \text{ bit}}_{\text{segno}} \underbrace{11 \text{ bit}}_{\text{esponente}} \underbrace{52 \text{ bit}}_{\text{mantissa}}.$$

- Range: $\approx [10^{-308}, 10^{308}]$.
- Precisione di macchina: $u = 2^{-52} \approx 2.2 \times 10^{-16}$.
- Ogni numero reale x è rappresentato da $\tilde{x}$ con $|\tilde{x} - x|/|x| \leq u$.
- Ogni operazione aritmetica introduce un errore relativo $\leq u$: $a \oplus b = (a + b)(1 + \delta)$, $|\delta| \leq u$.

Osservazione 7.1 (Problemi di cancellazione). Se si sottraggono due numeri quasi uguali, le cifre significative vengono annullate. Es. $1.000001 - 1.000000 = 0.000001$: con 7 cifre significative, il risultato ne ha solo 1. Algoritmi che evitano la cancellazione sono preferibili.

7.3 Stabilità degli algoritmi

Definizione 7.2 (Backward stability). Un algoritmo che calcola $\tilde{y} \approx f(x)$ è *backward stable* se:

$$\tilde{y} = f(\tilde{x}), \quad \frac{\|\tilde{x} - x\|}{\|x\|} = O(u).$$

L'output è l'esatto risultato per un input *leggermente perturbato*.

Teorema 7.3 (Backward stability del prodotto interno). Sia $y = a^\top b = \sum_{i=1}^n a_i b_i$ calcolato in macchina come $\tilde{y}$. Allora:

$$\tilde{y} = \tilde{a}^\top b = a^\top \tilde{b},$$

dove $\|\tilde{a} - a\| \leq nu\|a\| + O(u^2)$ e analogamente per b . Il prodotto interno è backward stable.

Prova (sketch). Ogni moltiplicazione $a_i \odot b_i = a_i b_i (1 + \delta_i)$, $|\delta_i| \leq u$. Le addizioni successive introducono ulteriori errori. Un'analisi rigorosa mostra che l'errore accumulato soddisfa:

$$|\tilde{y} - y| \leq nu \sum_i |a_i b_i| + O(u^2) \leq nu\|a\|_1 \|b\|_\infty.$$

L'algoritmo può essere visto come il calcolo esatto di $\tilde{a}^\top b$ con $\tilde{a}_i = a_i(1 + \varepsilon_i)$, $|\varepsilon_i| \leq (2i - 1)u$: backward stable. $\square$

Esempio 7.1 (Prodotto interno di vettori lunghi). Con $n = 1000$ e $u \approx 10^{-16}$: l'errore relativo del prodotto interno è $\leq 1000 \cdot 10^{-16} = 10^{-13}$. Ancora molto piccolo! Il prodotto interno è numericamente robusto.

Teorema 7.4 (Backward stability di Householder QR). La fattorizzazione QR tramite riflettori di Householder è backward stable: $\tilde{Q}\tilde{R} = A + E$ con $\|E\| = O(u\|A\|)$.

Attenzione

Il metodo di Gram-Schmidt classico **non** è backward stable: gli errori di cancellazione possono rendere le colonne di Q non ortogonali. Gram-Schmidt modificato è meglio, ma Householder rimane il metodo preferito.

7.3.1 Test a posteriori: analisi del residuo

Teorema 7.5 (Residual bound per sistemi lineari). Dato $\tilde{x} \approx A^{-1}b$ con residuo $r = A\tilde{x} - b$:

$$\frac{\|\tilde{x} - x^*\|}{\|x^*\|} \leq \kappa(A) \cdot \frac{\|r\|}{\|b\|}.$$

Se $\|r\|/\|b\| = O(u)$ (residuo piccolo in machine precision), allora l'algoritmo è backward stable. Ma l'errore forward può ancora essere grande se $\kappa(A) \gg 1$.

Capitolo 8

Fattorizzazione QR

8.1 Definizione e teorema

Teorema 8.1 (Fattorizzazione QR). Per ogni $A \in \mathbb{R}^{m \times n}$ con $m \geq n$, esistono:

- $Q \in \mathbb{R}^{m \times m}$ ortogonale.
- $R \in \mathbb{R}^{m \times n}$ triangolare superiore.

tali che $A = QR$. La thin QR è $A = \hat{Q}R$ con $\hat{Q} \in \mathbb{R}^{m \times n}$ (colonne ortonormali) e $R \in \mathbb{R}^{n \times n}$ triangolare superiore.

8.2 Riflettori di Householder

Il metodo numericamente stabile per calcolare la QR.

Definizione 8.1 (Riflettore di Householder). Dato un vettore $v \in \mathbb{R}^m$, il riflettore di Householder è:

$$H = I - 2 \frac{vv^\top}{\|v\|^2} \in \mathbb{R}^{m \times m}.$$

H è simmetrica e ortogonale ($H = H^\top$, $H^2 = I$). Riflette rispetto all'iperpiano ortogonale a v .

Proposizione 8.1 (Azzeramento di colonne). Dato $x \in \mathbb{R}^m$, si sceglie $v = x - \|x\|e_1$ (o $v = x + \|x\|e_1$ per stabilità numerica, scegliendo il segno opposto a x_1). Allora:

$$Hx = \|x\|e_1 = (\|x\|, 0, \dots, 0)^\top.$$

Questo azzerava tutti gli elementi sotto il primo.

Algoritmo: Fattorizzazione QR via Householder

Per $j = 1, \dots, n$:

1. Considera $x = A_{j:m,j}$ (colonna corrente a partire dalla diagonale).
2. Costruisci v_j tale che $H_j x = \|x\|e_1$.

3. Aggiorna: $A \leftarrow H_j A$ (applica il riflettore all'intera matrice).

Alla fine: $H_n \cdots H_1 A = R$ (triangolare sup.), quindi $Q = H_1 \cdots H_n$. **Costo:** $2mn^2 - \frac{2}{3}n^3$ flop.

Teorema 8.2 (Backward stability della QR). *La fattorizzazione QR calcolata con riflettori di Householder soddisfa:*

$$\tilde{Q}\tilde{R} = A + \Delta A, \quad \frac{\|\Delta A\|_F}{\|A\|_F} = O(u),$$

dove $u \approx 2.2 \times 10^{-16}$ è la precisione di macchina. La QR di Householder è **backward stable**.

8.3 Soluzione dei minimi quadrati con QR

Con la thin QR $A = \hat{Q}R$:

$$\|Ax - b\|^2 = \|\hat{Q}Rx - b\|^2 = \|Rx - \hat{Q}^\top b\|^2 + \|(I - \hat{Q}\hat{Q}^\top)b\|^2.$$

Il secondo termine non dipende da x . Quindi si risolve il sistema triangolare:

$$Rx^* = \hat{Q}^\top b.$$

Costo totale: QR in $O(mn^2)$, risoluzione $Rx = c$ in $O(n^2)$.

Attenzione

Le equazioni normali $A^\top Ax = A^\top b$ risolte con Cholesky hanno costo simile, ma l'errore numerico è proporzionale a $\kappa(A)^2$ anziché $\kappa(A)$. Preferire QR per problemi mal condizionati.

Capitolo 9

Decomposizione a Valori Singolari (SVD)

9.1 Definizione e proprietà

Teorema 9.1 (SVD — Singular Value Decomposition). *Per ogni $A \in \mathbb{R}^{m \times n}$ (con $m \geq n$), esistono:*

- $U \in \mathbb{R}^{m \times m}$ *ortogonale* (vettori singolari sinistri).
- $V \in \mathbb{R}^{n \times n}$ *ortogonale* (vettori singolari destri).
- $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_n) \in \mathbb{R}^{m \times n}$ con $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n \geq 0$.

tali che $A = U\Sigma V^\top$.

Prova per A quadrata. La matrice $A^\top A$ è simmetrica semidefinita positiva. Sia $A^\top A = VDV^\top$ la sua decomposizione spettrale con $D = \text{diag}(\sigma_1^2, \dots, \sigma_n^2)$, $\sigma_i \geq 0$. Poniamo $\Sigma = \sqrt{D}$ e $U_r = AV_r\Sigma_r^{-1}$ (vettori singolari sinistri per i valori singolari non nulli). Si verifica che $U_r^\top U_r = \Sigma_r^{-1}V_r^\top A^\top AV_r\Sigma_r^{-1} = I$, e completando U_r a una base ortonormale si ottiene U . $\square$

Definizione 9.1 (SVD thin/ridotta). Per $A \in \mathbb{R}^{m \times n}$ con $m \geq n$, la *thin SVD* è $A = \hat{U}\Sigma V^\top$ con $\hat{U} \in \mathbb{R}^{m \times n}$ (colonne ortonormali). Sufficiente per la maggior parte delle applicazioni.

Teorema 9.2 (Sottospazi fondamentali). *Dalla SVD $A = U\Sigma V^\top$ con $\text{rank } A = r$:*

- $\text{Im}(A) = \text{span}(u_1, \dots, u_r)$ (prime r colonne di U).
- $\text{ker}(A) = \text{span}(v_{r+1}, \dots, v_n)$ (ultimi $n - r$ colonne di V).
- $\text{Im}(A^\top) = \text{span}(v_1, \dots, v_r)$.
- $\text{ker}(A^\top) = \text{span}(u_{r+1}, \dots, u_m)$.

Definizione 9.2 (Pseudoinversa di Moore-Penrose). $A^+ = V\Sigma^+U^\top$, dove $\Sigma^+ = \text{diag}(\sigma_1^{-1}, \dots, \sigma_r^{-1}, 0, \dots, 0)$.

9.2 Teorema di Eckart-Young (approssimazione di basso rango)

Teorema 9.3 (Eckart-Young, 1936). Sia $A = U\Sigma V^\top$ e sia $A_k = \sum_{i=1}^k \sigma_i u_i v_i^\top$ il troncamento al rango k . Allora:

$$\|A - A_k\|_2 = \sigma_{k+1}, \quad \|A - A_k\|_F = \sqrt{\sigma_{k+1}^2 + \cdots + \sigma_n^2},$$

e A_k è il miglior approssimante di rango $\leq k$ di A in entrambe le norme.

Intuizione 9.1. A_k cattura le k “direzioni principali” di A (quelle con maggiore varianza/energia). Fondamentale per: PCA, compressione di immagini, sistemi di raccomandazione.

Esempio 9.1 (Matrice dei voti studenti). $A \in \mathbb{R}^{s \times t}$ con A_{ij} = voto dello studente i al test j . Se $A \approx A_1 = \sigma_1 u_1 v_1^\top$ (rango 1), allora $A_{ij} \approx \sigma_1 (u_1)_i (v_1)_j$: il voto è prodotto di una “abilità” dello studente per una “difficoltà” del test. Se $A \approx A_2$, ci sono due “dimensioni” di abilità.

Capitolo 10

Norme e Matrici Ortogonali

10.1 Norme vettoriali

Definizione 10.1. La famiglia delle p -norme: $\|x\|_p = (\sum_i |x_i|^p)^{1/p}$ per $p \geq 1$. La norma euclidea è $\|\cdot\|_2$; la norma $\|\cdot\|_\infty = \max_i |x_i|$; la norma $\|\cdot\|_1 = \sum_i |x_i|$.

10.2 Matrici ortogonali

Definizione 10.2. $U \in \mathbb{R}^{m \times m}$ è *ortogonale* se $U^\top U = UU^\top = I$.

Proposizione 10.1. Le matrici ortogonali *preservano la norma euclidea*: $\|Ux\|_2 = \|x\|_2$.
Conseguenza: i valori singolari di UA e AV (con U, V ortogonali) coincidono con quelli di A .

10.3 Norme di matrici

Definizione 10.3 (Norma *indotta*). La norma di matrice indotta dalla norma vettoriale $\|\cdot\|$ è:

$$\|A\| = \max_{\|x\|=1} \|Ax\| = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|}.$$

Teorema 10.1 (Norma *spettrale*). La norma indotta dalla norma *euclidea* è la norma spettrale:

$$\|A\|_2 = \sigma_1(A) = \max_i \sigma_i(A).$$

Per matrici ortogonali: $\|Q_1 A Q_2\|_2 = \|A\|_2$ (invarianza unitaria).

Definizione 10.4 (Norma di Frobenius). $\|A\|_F = \sqrt{\sum_{i,j} A_{ij}^2} = \sqrt{\sum_i \sigma_i^2}$. Anche la norma di Frobenius è unitariamente invariante.

Parte V

Livello 5 — Il Resto del Corso

Capitolo 11

Background: Algebra Lineare

11.1 Prodotto matriciale e interpretazioni

Osservazione 11.1 (Costo computazionale). Prodotto Av con $A \in \mathbb{R}^{m \times n}$: $O(mn)$ flop. Prodotto AB con $B \in \mathbb{R}^{n \times p}$: $O(mnp)$. **Regola fondamentale:** $A(Bv)$ costa $O(mn + np)$, mentre $(AB)v$ costa $O(mnp + mp)$ — non formare mai esplicitamente AB se si vuole solo ABv .

11.2 Sistemi triangolari

Un sistema $Lx = b$ con L triangolare inferiore si risolve con *forward substitution* in $O(n^2)$; $Ux = b$ con U triangolare superiore con *back substitution*.

Attenzione

Non calcolare mai A^{-1} esplicitamente per risolvere $Ax = b$: il costo è $O(n^3)$ (come LU) ma il risultato è meno accurato. Usare $A \backslash b$ in Matlab o `np.linalg.solve` in Python.

11.3 Autovalori e forme quadratiche

Teorema 11.1 (Teorema spettrale). Ogni $A = A^T \in \mathbb{R}^{n \times n}$ si decompone come $A = Q\Lambda Q^T$ con Q ortogonale, $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$, $\lambda_i \in \mathbb{R}$.

Definizione 11.1 (Definitezza). $Q \succ 0$ (definita positiva) $\Leftrightarrow \lambda_i > 0$ per ogni $i \Leftrightarrow x^T Q x > 0$ per ogni $x \neq 0$.

Proposizione 11.1. Per ogni $A \in \mathbb{R}^{m \times n}$: $A^T A \succeq 0$. Se A ha rango massimo ($\text{rank } A = n \leq m$): $A^T A \succ 0$.

Parte VI

Livello 6 — Distante dal Progetto

Capitolo 12

Semplici Problemi di Ottimizzazione

12.1 Formulazione generale

Definizione 12.1 (Problema di ottimizzazione). Dato un insieme *ammissibile* $S \subseteq \mathbb{R}^n$ e una funzione *obiettivo* $f : S \rightarrow \mathbb{R}$, il problema è:

$$f^* = \min_{x \in S} f(x).$$

Un punto $x^* \in S$ tale che $f(x^*) = f^*$ è una *soluzione ottima* (o *minimizzatore*).

Osservazione 12.1. Il valore ottimo f^* è unico se esiste, ma possono esistere più minimizzatori x^* . Massimizzare $g(x)$ equivale a minimizzare $f(x) = -g(x)$. Un punto x_ε è una *soluzione ε -ottima* se $f(x_\varepsilon) \leq f^* + \varepsilon$.

12.1.1 Minimi locali vs globali

Definizione 12.2. x^* è un *minimo locale* se esiste $\delta > 0$ tale che $f(x^*) \leq f(x)$ per ogni $x \in S$ con $\|x - x^*\| \leq \delta$. È un *minimo globale* se $f(x^*) \leq f(x)$ per ogni $x \in S$.

Per funzioni convesse, ogni minimo locale è globale. Per funzioni non convesse, possono esistere minimi locali che non sono globali — trovare il globale è in generale NP-difficile.

12.2 Ottimizzazione univariata (1D)

Il caso $n = 1$ è fondamentale perché molte line search si riducono a questo.

Definizione 12.3 (Funzione unimodale). $f : [a, b] \rightarrow \mathbb{R}$ è unimodale se esiste $x^* \in [a, b]$ tale che f è strettamente decrescente su $[a, x^*]$ e strettamente crescente su $[x^*, b]$.

12.2.1 Golden Section Search

Algoritmo: Golden Section Search

Dato f unimodale su $[a, b]$, con $\tau = (\sqrt{5} - 1)/2 \approx 0.618$:

1. $x_1 = a + (1 - \tau)(b - a)$, $x_2 = a + \tau(b - a)$.
2. Se $f(x_1) < f(x_2)$: poni $b \leftarrow x_2$, altrimenti $a \leftarrow x_1$.
3. Aggiorna il punto interno rimanente senza ricalcolarlo (1 valutazione per passo).
4. Ripeti finché $|b - a| \leq \varepsilon$.

Dopo k passi, l'intervallo si è ridotto a $(b - a) \cdot \tau^k$. Costo: $O(\log(1/\varepsilon))$ valutazioni.

Intuizione 12.1. La scelta di $\tau = (\sqrt{5} - 1)/2$ (rapporto aureo) garantisce che il punto “risparmiato” cada nella posizione giusta nel sotto-intervallo successivo: un’elegante proprietà di auto-similarità.

12.2.2 Metodo di Newton 1D

Per $f \in C^2$, partendo da x_0 :

$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}.$$

Convergenza *quadratica* ($\|e_{k+1}\| = O(\|e_k\|^2)$) vicino a una radice di f' con $f''(x^*) \neq 0$.

Capitolo 13

Ottimizzazione Vincolata

13.1 Formulazione e topologia

Definizione 13.1 (Problema vincolato).

$$\min_{x \in \mathbb{R}^n} f(x) \quad \text{s.t.} \quad g_i(x) \leq 0, \quad i = 1, \dots, m; \quad h_j(x) = 0, \quad j = 1, \dots, p.$$

Teorema 13.1 (Weierstrass). *Se f è continua e $S \subseteq \mathbb{R}^n$ è compatto e non vuoto, il minimo è attinto.*

Osservazione 13.1. Per il problema vincolato, un punto stazionario di f su $\mathbb{R}^n$ potrebbe essere inammissibile. Le condizioni di ottimalità richiedono una nozione diversa.

13.2 Condizioni KKT

13.2.1 Vincoli attivi e LICQ

Definizione 13.2 (Vincoli attivi). All'ottimo x^* , il vincolo g_i è *attivo* se $g_i(x^*) = 0$, altrimenti *inattivo* ($g_i(x^*) < 0$).

Definizione 13.3 (LICQ — Linear Independence Constraint Qualification). Condizione LICQ: i gradienti dei vincoli attivi in x^* sono linearmente indipendenti.

Teorema 13.2 (Condizioni KKT — Karush-Kuhn-Tucker). *Se x^* è un minimo locale e vale LICQ, esistono moltiplicatori $\mu^* \in \mathbb{R}^m$, $\lambda^* \in \mathbb{R}^p$ tali che:*

$$\begin{aligned} \nabla f(x^*) + \sum_{i=1}^m \mu_i^* \nabla g_i(x^*) + \sum_{j=1}^p \lambda_j^* \nabla h_j(x^*) &= 0 && \text{(stazionarietà)} \\ g_i(x^*) &\leq 0, \quad h_j(x^*) = 0 && \text{(ammissibilità)} \\ \mu_i^* &\geq 0 && \text{(non negatività)} \\ \mu_i^* g_i(x^*) &= 0 \quad \forall i && \text{(complementarità)} \end{aligned}$$

Intuizione 13.1. Al minimo vincolato, il gradiente di f deve trovarsi nel *cono normale* all'insieme ammissibile in x^* : non si può migliorare f lungo nessuna direzione ammissibile.

La condizione di complementarità $\mu_i^* g_i(x^*) = 0$ dice: o il vincolo g_i è inattivo (e il suo moltiplicatore è zero), oppure il moltiplicatore è positivo (e il vincolo è attivo, in equilibrio).

Teorema 13.3 (Condizioni del secondo ordine). *Siano soddisfatte le KKT in x^* . Definiamo il Lagrangiano ridotto:*

$$L(x) = f(x) + \sum_i \mu_i^* g_i(x) + \sum_j \lambda_j^* h_j(x).$$

- **Necessaria:** $d^\top \nabla^2 L(x^*) d \geq 0$ per ogni d nel cono critico.
- **Sufficiente:** $d^\top \nabla^2 L(x^*) d > 0$ per ogni $d \neq 0$ nel cono critico $\Rightarrow x^*$ minimo locale isolato.

13.2.2 Lemma di Farkas e dualità

Lemma 13.1 (Farkas). *Per $A \in \mathbb{R}^{m \times n}$, $c \in \mathbb{R}^n$, esattamente una delle seguenti è vera:*

1. *Esiste $x \geq 0$ con $Ax = c$.*
2. *Esiste y con $A^\top y \geq 0$ e $c^\top y < 0$.*

Il Lemma di Farkas è lo strumento fondamentale nella dimostrazione delle condizioni KKT.

13.3 Dualità Lagrangiana

Definizione 13.4 (Funzione Lagrangiana).

$$L(x, \mu, \lambda) = f(x) + \mu^\top g(x) + \lambda^\top h(x), \quad \mu \geq 0.$$

Definizione 13.5 (Funzione duale di Lagrange).

$$q(\mu, \lambda) = \inf_{x \in \mathbb{R}^n} L(x, \mu, \lambda).$$

q è sempre concava (anche se f, g, h non lo sono).

Teorema 13.4 (Weak duality). *Per ogni x ammissibile e $(\mu \geq 0, \lambda)$: $q(\mu, \lambda) \leq f^*$.*

Il problema duale $\max_{\mu \geq 0, \lambda} q(\mu, \lambda)$ fornisce sempre un lower bound su f^ .*

Definizione 13.6 (Duality gap). $f^* - q^* \geq 0$. Si ha *strong duality* quando $f^* = q^*$.

Teorema 13.5 (Condizione di Slater (strong duality per problemi convessi)). *Se il problema è convesso (f, g_i convesse, h_j affini) ed esiste $\hat{x}$ strettamente ammissibile ($g_i(\hat{x}) < 0$ per ogni i , $h_j(\hat{x}) = 0$ per ogni j), allora vale la strong duality: $f^* = q^*$.*

Esempio 13.1 (Dualità LP). $\min_x c^\top x$ s.t. $Ax = b$, $x \geq 0$ ha duale $\max_y b^\top y$ s.t. $A^\top y \leq c$. Per LP, la strong duality vale sempre (quando entrambi sono ammissibili).

Esempio 13.2 (Dualità QP). Per $\min \frac{1}{2}x^\top Qx + c^\top x$ s.t. $Ax = b$, $Q \succ 0$:

$$q(\lambda) = -\frac{1}{2}(c + A^\top \lambda)^\top Q^{-1}(c + A^\top \lambda) - b^\top \lambda.$$

Funzione duale quadratica concava, strong duality vale.

13.4 Algoritmi per l'ottimizzazione vincolata

13.4.1 Gradiente proiettato

Definizione 13.7 (Proiezione su insieme convesso). $\Pi_C(x) = \arg \min_{y \in C} \|y - x\|^2$. Unica per C convesso chiuso.

Algoritmo: Projected Gradient Descent

$$x_{k+1} = \Pi_S(x_k - \alpha_k \nabla f(x_k)).$$

Converge come GD standard se f è smooth e convessa, S è convesso.

Esempio 13.3 (Proiezioni facili). • Simplexso $\Delta = \{x \geq 0 : \sum x_i = 1\}$: $O(n \log n)$.

- Box $[l, u]$: $\Pi_{[l, u]}(x)_i = \max(l_i, \min(u_i, x_i))$.
- Palla $\|x\| \leq r$: $\Pi(v) = r \cdot v / \max(r, \|v\|)$.

13.4.2 Metodo di Frank-Wolfe (Conditional Gradient)

Algoritmo: Frank-Wolfe

1. Linearizza f in x_k : $s_k = \arg \min_{x \in C} \nabla f(x_k)^\top x$.
2. Aggiorna: $x_{k+1} = x_k + \alpha_k(s_k - x_k)$, $\alpha_k = 2/(k+2)$.

Costo per passo: solo la minimizzazione lineare su C (molto più facile della proiezione per certi insiemi, es. poliedri).

Teorema 13.6 (Convergenza Frank-Wolfe). Per f convessa L -smooth su C compatto (diametro D):

$$f(x_k) - f^* \leq \frac{2LD^2}{k+2}.$$

13.4.3 Metodi barriera (Interior Point)

Idea: approssima il vincolo $g(x) \leq 0$ con la *funzione barriera logaritmica* $-t \log(-g(x))$:

$$\min_x f(x) - t \sum_i \log(-g_i(x)) \quad (\text{nessun vincolo!}).$$

Si risolve una sequenza di problemi al diminuire di $t \rightarrow 0$. Il percorso delle soluzioni al variare di t è detto *central path*. I metodi interior point hanno complessità polinomiale e sono la scelta per LP/QP/SOCP di grande scala.

Capitolo 14

Riepilogo: Connessioni tra NLA e Ottimizzazione

Le due parti del corso sono strettamente interconnesse:

1. **CG è sia ottimizzazione che algebra lineare:** risolvere $Qx = v$ con $Q \succ 0$ equivale a minimizzare $\frac{1}{2}x^\top Qx - v^\top x$. Stessa ricorrenza, due interpretazioni.
2. **Il passo di Newton richiede un sistema lineare:** $H_f(x_k)d_k = -\nabla f(x_k)$. Per sistemi grandi, Newton “inesatto” usa CG o GMRES per risolvere il sistema approssimativamente.
3. **Le equazioni normali del LS sono SPD:** $A^\top Ax = A^\top b$, risolto con Cholesky $O(\frac{1}{3}n^3)$, ma QR è preferibile per stabilità (κ^2 vs κ).
4. **SVD e PCA:** la decomposizione a valori singolari è lo strumento fondamentale per la compressione dei dati, il calcolo della pseudoinversa, e l’analisi della sensitività.
5. **Sistemi KKT:** i punti stazionari di problemi con vincoli di uguaglianza soddisfano il sistema saddle-point:

$$\begin{pmatrix} H & A^\top \\ A & 0 \end{pmatrix} \begin{pmatrix} x \\ \lambda \end{pmatrix} = \begin{pmatrix} -\nabla f \\ 0 \end{pmatrix}.$$

Questo è un sistema lineare simmetrico ma indefinito (non SPD): richiedono $LDL^\top$ con pivoting.

6. **Regolarizzazione di Tikhonov:** il problema di regressione $\|Ax - b\|^2 + \delta\|x\|^2$ è un problema LS regolarizzato. La soluzione si ottiene con SVD: $x_\delta = V \text{diag}(\sigma_i/(\sigma_i^2 + \delta))U^\top b$. Il parametro δ bilancia fit dei dati e norma della soluzione (bias-variance tradeoff in ML).

Parte VII

Domande d'Esame Orale

Questa parte raccoglie domande tipiche d'orale con risposta modello, organizzate per area e mappate ai capitoli precedenti. Il peso e' sulla parte di *analisi e ottimizzazione* (Deflected Subgradient), che e' la piu' richiesta sul progetto. Ogni risposta e' tarata sulla lunghezza di un'esposizione orale; i riquadri **Trappola d'esame** segnalano gli errori piu' frequenti o i punti gia' contestati dal docente.

Capitolo 15

Domande — Progetto ML-25 (ELM + LASSO)

D1. Cos'è un'Extreme Learning Machine e perché l'addestramento si riduce a un problema lineare?

Una ELM è una rete a un solo strato nascosto in cui la matrice dei pesi input-hidden $\mathbf{W}_1$ è generata a caso e tenuta fissa; si ottimizzano solo i pesi di output $\mathbf{w} \in \mathbb{R}^H$. Fissata $\mathbf{W}_1$, le attivazioni $\mathbf{X} = \sigma(\mathbf{X}_{\text{orig}} \mathbf{W}_1^\top) \in \mathbb{R}^{M \times H}$ sono costanti. La predizione $\hat{\mathbf{y}} = \mathbf{w}^\top \sigma(\mathbf{W}_1 \mathbf{x})$ è lineare in $\mathbf{w}$, quindi addestrare significa risolvere un problema di minimi quadrati in $\mathbf{w}$. Con la penalità L_1 diventa il LASSO $\min_{\mathbf{w}} \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 + \lambda \|\mathbf{w}\|_1$. **Trappola d'esame:** Non dire che “si addestra la rete”. Il non-linear sta tutto in σ e in $\mathbf{W}_1$, che sono congelati; l'unica ottimizzazione è convessa e riguarda $\mathbf{w}$. Rif.: Cap. 1, §1.1; report Cap. 1.

D2. Perché il problema è convesso? È strettamente convesso? Esiste ed è unico il minimo?

$f = g + h$ con $g(\mathbf{w}) = \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2$ (convessa, $\nabla^2 g = \mathbf{X}^\top \mathbf{X} \succeq \mathbf{0}$) e $h = \lambda \|\mathbf{w}\|_1$ (convessa come multiplo di norma): la somma è convessa. Se $\mathbf{X}$ ha rango pieno colonna allora $\mathbf{X}^\top \mathbf{X} \succ \mathbf{0}$, g è strettamente convessa e quindi lo è f (stretta + convessa = stretta). Inoltre g è coerciva ($g \rightarrow +\infty$ per $\|\mathbf{w}\| \rightarrow \infty$) e $h \geq 0$, dunque f è coerciva: i sublivelli sono compatti, f continua $\Rightarrow$ minimo attinto (Weierstrass); la stretta convessità lo rende unico $\mathbf{w}^*$. **Trappola d'esame:** La convessità stretta non basta per l'esistenza (es. e^x): serve la coercività. Cita entrambe. Rif.: report Cap. 1, Prop. “irls_prop”; Cap. 1.

D3. Scrivi la condizione di ottimalità. Cosa dice sui pesi nulli?

$\mathbf{w}^*$ è ottimo $\iff \mathbf{0} \in \partial f(\mathbf{w}^*)$, cioè per ogni componente $[\mathbf{X}^\top (\mathbf{X}\mathbf{w}^* - \mathbf{y})]_i + \lambda s_i = 0$ con $s_i \in \partial |w_i^*|$. Per $w_i^* \neq 0$: $s_i = \text{sign}(w_i^*)$. Per $w_i^* = 0$: $s_i \in [-1, 1]$, che equivale a $|[\mathbf{X}^\top (\mathbf{X}\mathbf{w}^* - \mathbf{y})]_i| \leq \lambda$. Quest'ultima è la spiegazione analitica della sparsità: una componente resta a zero finché la “forza” del residuo su quella feature non supera la

soglia λ . Rif.: report §“intro_optimality”; Cap. 1, Prop.

D4. (IRLS) Qual è l'idea e perché funziona? Cos'è il framework MM?

IRLS rende liscio il termine L_1 con la *maggiorazione* $|w_i| \leq \frac{w_i^2}{2|w_{k,i}|} + \frac{|w_{k,i}|}{2}$ (da $(|w_i| - |w_{k,i}|)^2 \geq 0$), che dà $\lambda \|\mathbf{w}\|_1 \leq \frac{\lambda}{2} \mathbf{w}^\top \mathbf{W}_k^\top \mathbf{W}_k \mathbf{w} + \text{cost}$ con $(\mathbf{W}_k)_{ii} = |w_{k,i}|^{-1/2}$. Questo è un caso di *Majorization-Minimization*: si costruisce un surrogato $Q(\mathbf{w}, \mathbf{w}_k) \geq f(\mathbf{w})$ che tocca f in $\mathbf{w}_k$ e si minimizza Q . Le due proprietà MM danno $f(\mathbf{w}_{k+1}) \leq Q(\mathbf{w}_{k+1}, \mathbf{w}_k) \leq Q(\mathbf{w}_k, \mathbf{w}_k) = f(\mathbf{w}_k)$: *discesa monotona garantita*, a differenza del subgradiente. Rif.: report Cap. 2, §“irls_mm”; Cap. 1.2.

D5. (IRLS) Che sotto-problema risolvi a ogni passo e come?

Minimizzando il surrogato si ottiene un *minimi-quadrati pesati con regolarizzazione L_2* , le cui equazioni normali sono il sistema *SPD* $(\mathbf{X}^\top \mathbf{X} + 2\lambda_{\text{IRLS}} \mathbf{W}_k^\top \mathbf{W}_k) \mathbf{w}_{k+1} = \mathbf{X}^\top \mathbf{y}$, con $\lambda_{\text{IRLS}} = \frac{1}{2} \lambda_{\text{LASSO}}$. La matrice è *SPD* ($\mathbf{X}^\top \mathbf{X} \succeq 0$ più termine diagonale $\succ 0$), quindi si risolve con *Cholesky* ($O(H^3/3)$) o, per H grande, con *CG*. $\mathbf{A} = \mathbf{X}^\top \mathbf{X}$ e $\mathbf{b} = \mathbf{X}^\top \mathbf{y}$ si *precalcolano* una volta ($O(MH^2)$); a ogni iterazione cambia solo la diagonale ($O(H)$). **Trappola d'esame:** Il fattore $\frac{1}{2}$ in λ_{IRLS} non è arbitrario: viene dalla costante della maggiorazione ed è ciò che fa coincidere il punto fisso di IRLS con l'ottimo LASSO. Rif.: report Cap. 2, Prop. “irls_normal”.

D6. (IRLS) Cosa sai dire sulla convergenza? Che tasso?

Due livelli. (1) *Consistenza del punto fisso*: se la successione converge a $\mathbf{w}^*$ con tutte le componenti $> \varepsilon_{\text{thr}}$, allora $\mathbf{w}^*$ soddisfa l'ottimalità LASSO (si verifica che il termine pesato diventa $\text{sign}(\mathbf{w}^*)$). (2) *Tasso*: scrivendo IRLS come mappa di punto fisso $\mathcal{M}(\mathbf{w}) = \mathbf{Q}(\mathbf{w})^{-1} \mathbf{b}$, in $\mathbf{w}^*$ è C^1 con raggio spettrale $\rho(\nabla \mathcal{M}(\mathbf{w}^*)) < 1$; per il teorema di attrazione di Ostrowski la convergenza locale è *lineare*. **Trappola d'esame:** Non citare il risultato di rate lineare di Daubechies (Thm 5.3): assume la *null space property* per recovery sparso *sottodeterminato*, mentre qui siamo *sovradeterminati* ($M > H$) e *fortemente convessi*. Citazione mis-applicata = errore grave. Usa Ostrowski. Rif.: report Cap. 2, §“irls_convergence”.

D7. (IRLS) IRLS produce davvero soluzioni sparse esatte?

No, non zeri esatti. Il clip $(\mathbf{W}_k)_{ii} = (\max(|w_{k,i}|, \varepsilon_{\text{thr}}))^{-1/2}$ trasforma il problema in una variante *smussata* (tipo Huber) del LASSO: L_1 è sostituito da una funzione che vale $|w_i|$ per $|w_i| > \varepsilon_{\text{thr}}$ e quadratica sotto soglia. Il minimo differisce da quello LASSO di $O(\varepsilon_{\text{thr}})$ e lo recupera per $\varepsilon_{\text{thr}} \rightarrow 0$. Con $\varepsilon_{\text{thr}} = 10^{-8}$ la differenza non è distinguibile dal solver di riferimento. La sparsità “vera” richiede una sogliatura a posteriori. Rif.: report Cap. 2, verifica ipotesi punto 2.

D8. IRLS vs DSM: quando usare quale?

IRLS: poche iterazioni (50–100), ciascuna costosa ($O(H^3)$ per il solve), *discesa monotona*, *alta precisione* raggiungibile ($\varepsilon < 10^{-8}$), tasso lineare. **DSM**: iterazione cheap ($O(MH)$, solo un subgradiente e un prodotto matrice-vettore), ma *molte iterazioni*, sequenza *non monotona*, precisione limitata ($\varepsilon \sim 10^{-3}/10^{-4}$), tasso $O(1/\sqrt{k})$. Regola: IRLS se serve precisione; DSM competitivo in tempo CPU a bassa precisione o quando H è così grande da rendere Cholesky proibitivo. Entrambi devono risolvere lo *stesso* problema (stessi λ , stessa $\mathbf{X}$). Rif.: Cap. 1.4; report Cap. 4.

Capitolo 16

Domande — Ottimizzazione Non-Smooth e Deflected Subgradient

D9. Definizione di subgradiente e subdifferenziale. Condizione di ottimalità non-smooth.

g è un subgradiente di f convessa in x se $f(y) \geq f(x) + g^\top(y - x)$ per ogni y (ogni g definisce un iperpiano di supporto sotto il grafico). L'insieme $\partial f(x)$ è il subdifferenziale: nei punti lisci è il singoletto $\{\nabla f\}$, negli spigoli è un insieme. Ottimalità: x^* minimo globale $\iff 0 \in \partial f(x^*)$. Per $|x|$ in 0: $\partial|0| = [-1, 1]$. Rif.: Cap. 2.1, Def.; report Cap. 3.

D10. Perché non si può fare gradient descent sul LASSO? E perché non basta “prendere un subgradiente qualsiasi”?

f non è differenziabile dove qualche $w_i = 0$, quindi ∇f non esiste lì. Il punto più sottile: anche prendendo $g \in \partial f$, $-g$ non è una direzione di discesa. Nel caso liscio $-\nabla f$ garantisce $f(x + \alpha d) < f(x)$ per α piccolo; nel non-smooth questo può fallire per qualunque $\alpha > 0$. Crolla tutto l'apparato (line search di Armijo, test di discesa). Serve una teoria diversa: il metodo del subgradiente, che non garantisce discesa monotona ma convergenza del record $\bar{f}^i = \min_{h \leq i} f(w_h)$. Trappola d'esame: È l'errore concettuale più comune: “uso un subgradiente come se fosse il gradiente”. No — $-g$ non è di discesa, per questo si lavora sul record e non sul valore corrente. Rif.: report §“dsm_motivation”; tutorial DSM, Parte II.

D11. Cos'è il record value e perché è necessario?

$\bar{f}^i = \min_{h \leq i} f(w_h)$: il miglior valore visto fino a i . Poiché la successione $f(w_i)$ oscilla (può crescere da un'iterazione all'altra), gli enunciati di convergenza riguardano $\bar{f}^i \rightarrow f^*$, non $f(w_i) \rightarrow f^*$. Praticamente: si tiene in memoria w_{best} e si restituisce quello. Rif.: Cap. 2.1; report §“dsm_properties”.

D12. Deriva il passo di Polyak. Perché è “ottimale”?

Dalla disuguaglianza fondamentale $\|\mathbf{w}_{i+1} - \mathbf{w}^*\|^2 \leq \|\mathbf{w}_i - \mathbf{w}^*\|^2 - 2\alpha_i(f(\mathbf{w}_i) - f^*) + \alpha_i^2 \|\mathbf{g}_i\|^2$ (si ottiene espandendo $\|\mathbf{w}_i - \alpha_i \mathbf{g}_i - \mathbf{w}^*\|^2$ e usando la disuguaglianza del subgradiente $\mathbf{g}_i^\top (\mathbf{w}_i - \mathbf{w}^*) \geq f(\mathbf{w}_i) - f^*$). Il membro destro è una parabola in α_i , minimizzata da $\alpha_i^* = (f(\mathbf{w}_i) - f^*) / \|\mathbf{g}_i\|^2$: è il passo che massimizza la riduzione garantita della distanza dall’ottimo a quell’iterazione. **Trappola d’esame:** “Ottimale” significa che minimizza il bound sulla distanza per quel singolo passo, non che minimizza f lungo la direzione (non è una line search esatta). Rif.: report §“dsm_target_level”, eq. fundamental; tutorial DSM, Parte III.

D13. Qual è il tasso del subgradiente con passo di Polyak? È migliorabile?

$\bar{f}^k - f^* \leq \frac{G \|\mathbf{w}_0 - \mathbf{w}^*\|}{\sqrt{k+1}}$, cioè $O(1/\sqrt{k})$ (equivalente a $O(L^2/\varepsilon^2)$ iterazioni per ε -accuratezza), con G bound di Lipschitz/sui subgradienti. Questo tasso è ottimale per metodi del primo ordine su funzioni convesse non-smooth Lipschitz: il lower bound di Nemirovski–Yudin è $\Omega(L^2/\varepsilon^2)$. Quindi nessun metodo del primo ordine può fare meglio in peggior caso — la deflection non cambia l’ordine asintotico. Rif.: Cap. 1.3.1; report §“dsm_convergence”, Complexity.

D14. Cos’è la deflection e a cosa serve? Scrivi la direzione.

$\mathbf{d}_i = \gamma_i \mathbf{g}_i + (1 - \gamma_i) \mathbf{d}_{i-1}$, $\gamma_i \in (0, 1]$, con $\mathbf{d}_0 = \mathbf{g}_0$. Mescola il subgradiente corrente con la direzione precedente (memoria): $\gamma_i = 1$ recupera il subgradiente puro, $\gamma_i < 1$ smorza lo zig-zag che il subgradiente puro produce su $\mathbf{X}^\top \mathbf{X}$ mal condizionata. Il subgradiente puro oscilla perché vicino a $\mathbf{w}^*$ il subgradiente non è piccolo (in $\mathbf{w}^*$, $\mathbf{0} \in \partial f$ ma il subdifferenziale contiene anche vettori non nulli): il passo resta “lungo” e si salta avanti-indietro. La memoria media queste oscillazioni. Rif.: report §“dsm_deflection”; Cap. 1.3.

D15. Deriva la scelta ottimale di γ_i in forma chiusa.

Si sceglie γ_i che minimizza $\|\mathbf{d}_i\|^2 = \|\gamma \mathbf{g}_i + (1 - \gamma) \mathbf{d}_{i-1}\|^2$ su $[\gamma_{\min}, 1]$. È una parabola convessa in γ ; il vertice dà $\gamma^* = \frac{\|\mathbf{d}_{i-1}\|^2 - \mathbf{g}_i^\top \mathbf{d}_{i-1}}{\|\mathbf{g}_i - \mathbf{d}_{i-1}\|^2}$, poi $\gamma_i = \min(1, \max(\gamma_{\min}, \gamma^*))$. Minimizzare $\|\mathbf{d}_i\|^2$ ha senso perché è il denominatore del passo di Polyak: $\|\mathbf{d}_i\|^2$ piccola $\Rightarrow$ passo α_i grande. **Trappola d’esame:** Caso degenerare $\mathbf{g}_i = \mathbf{d}_{i-1}$: coefficiente quadratico nullo, si pone $\gamma_i = 1$ per convenzione. Primo passo: $\mathbf{d}_{-1} = \mathbf{0} \Rightarrow \gamma^* = 0$, ma si forza $\gamma_0 = 1$ così $\mathbf{d}_0 = \mathbf{g}_0$. Rif.: report eq. “gamma_star”; Appendice gamma-star.

D16. Perché introdurre il floor $\gamma_{\min} > 0$? (È un'aggiunta vostra)

La condizione di convergenza (3.5) di d'Antonio–Frangioni richiede, quando il passo è attivo, un bound uniforme $\beta_i \geq \beta^* > 0$ sul moltiplicatore di stepsize, non solo $\beta_i > 0$ puntuale. La formula greedy tiene $\gamma_i \in (0, 1]$ a ogni passo ma non la limita lontano da zero: quando i subgradienti consecutivi si allineano (vicino alla stazionarietà) il numeratore di γ^* tende a 0^+ , e con esso β_i e il passo. Proiettando su $[\gamma_{\min}, 1]$ si fornisce il bound mancante con $\beta^* = \gamma_{\min}$. Scegliamo $\gamma_{\min} = 0.05$. **Trappola d'esame:** È un floor (limite inferiore), non un valore fisso di γ . Serve per far valere l'ipotesi del teorema sul nostro problema, non per “comodità numerica”. Rif.: report §“dsm_convergence_conditions”.

D17. Cos'è il meccanismo target-level e perché serve?

Il passo di Polyak richiede f^* , che è incognito. Lo si sostituisce con un target level $f_{\text{ref}} - \delta$, dove f_{ref} è il miglior valore trovato e $\delta > 0$ stima il gap residuo. Il rischio è $f_{\text{ref}} - \delta < f^*$ (target irraggiungibile): allora il test di discesa sufficiente $f(\mathbf{w}_{i+1}) \leq f_{\text{ref}} - \delta/2$ non scatta mai e l'algoritmo stalla in silenzio. Una guardia evita questo: un contatore di “pazienza” $r_i = \sum \alpha_j \|\mathbf{d}_j\|$ (distanza percorsa); se supera una soglia R senza discesa sufficiente, si contrae $\delta \mapsto \rho\delta$ ($\rho \in (0, 1)$) e si azzerava r . Le contrazioni ripetute portano $\delta \rightarrow 0$, riportando $f_{\text{ref}} - \delta \geq f^*$ e sbloccando il test. Rif.: report §“dsm_target_level”; Cap. 1.3.

D18. (CHIAVE) Perché gli iterati restano limitati? Perché NON puoi usare l'argomento del sublivello?

Perché il metodo è non monotono in f : la successione $f(\mathbf{w}_i)$ può crescere, quindi non si può affermare che gli iterati restino nel sublivello $\{f \leq f(\mathbf{w}_0)\}$ — quell'argomento vale solo per metodi di discesa. La limitatezza si ottiene invece con la monotonicità di Fejér: appena il target diventa feasible ($t_i = (f_{\text{ref}} - \delta) - f^* \geq 0$, cosa garantita dalla contrazione $\delta \rightarrow 0$ da un certo indice in poi), la disuguaglianza per-passo dà $\|\mathbf{w}_{i+1} - \mathbf{w}^*\| \leq \|\mathbf{w}_i - \mathbf{w}^*\|$: la distanza dall'ottimo non cresce. Coda limitata (Fejér) + transiente finito di punti finiti $\Rightarrow \{\mathbf{w}_i\}$ limitata; su un limitato ∂f è limitato, da cui $\|\mathbf{g}_i\| \leq L$. **Trappola d'esame:** Questo è uno dei due errori che il docente ha già trovato: “boundedness via sublevel set su un metodo non-monotono”. Devi enunciare direttamente l'argomento di Fejér. La distanza a $\mathbf{w}^*$ è monotona (sulla coda), i valori no. Rif.: report dim. Teorema DSM, paragrafi “Tail” e “Transient”.

D19. (CHIAVE) Cos'era sbagliato nel vecchio Teorema 3.1 del report?

L'errore: si applicava la disuguaglianza del subgradiente alla direzione deflessa $\mathbf{d}_i$, scrivendo $\mathbf{d}_i^\top (\mathbf{w}_i - \mathbf{w}^*) \geq f(\mathbf{w}_i) - f^*$. Ma quella disuguaglianza vale solo per un subgradiente $\mathbf{g}_i \in \partial f(\mathbf{w}_i)$: $\mathbf{d}_i$ è una combinazione convessa di subgradienti presi in punti diversi ($\mathbf{g}_0, \dots, \mathbf{g}_i$), quindi in generale non è un subgradiente di f in $\mathbf{w}_i$ e

la disuguaglianza non si applica. La dimostrazione corretta (d’Antonio–Frangioni) non passa da lì: introduce la quantità ν_i e usa il loro Corollario 3.2 per limitare $\mathbf{d}_i^\top(\mathbf{w}_i - \mathbf{w}^*)$ propriamente, mantenendo valida solo $\mathbf{g}_i^\top(\mathbf{w}_i - \mathbf{w}^*) \geq f(\mathbf{w}_i) - f^*$ (che è vera). **Trappola d’esame:** Domanda probabile: “nel caso del subgradiente puro avevi applicato la disuguaglianza al passo, perché ora no?” Risposta: nel puro la direzione è $\mathbf{g}_i$; col deflesso la direzione è $\mathbf{d}_i \neq \mathbf{g}_i$. Rif.: tutorial DSM, Parte “Errata”.

D20. Enuncia il teorema di convergenza del DSM (SGPTL) e come verifichi le ipotesi sul vostro problema.

Se f è convessa con $f^* > -\infty$ attinto, i subgradienti incontrati sono uniformemente limitati ($\|\mathbf{g}_i\| \leq L$) e vale la regola stepsize-restricted $\beta_i \leq \gamma_i$ con $\gamma_i \geq \gamma_{\min} > 0$, allora $f^k \rightarrow f^*$ e, una volta che il target si è affinato a f^* , il rate è $f^k - f^* \leq \frac{L \|\mathbf{w}_0 - \mathbf{w}^*\|}{\gamma_{\min} \sqrt{k+1}}$. Verifica sul nostro problema: (i) f^* attinto $\leftarrow$ coercività (Prop. del Cap. 1); (ii) limitatezza dei subgradienti $\leftarrow$ argomento di Fejér $\Rightarrow$ iterati limitati $\Rightarrow \partial f$ limitato; (iii) $\beta_i = \min(1, \gamma_i) \leq \gamma_i$ per costruzione e $\gamma_i \geq \gamma_{\min}$ per il floor. Formalmente si verificano le condizioni (2.13), (3.5), (3.26) di d’Antonio–Frangioni con inesattezza dell’oracolo $\sigma = 0$. Rif.: report Teorema “dsm_convergence” e verifica ipotesi.

D21. Da dove viene il fattore $1/\gamma_{\min}$ nel rate? Quanto costa?

Dalla disuguaglianza per-passo $\|\mathbf{w}_{i+1} - \mathbf{w}^*\|^2 \leq \|\mathbf{w}_i - \mathbf{w}^*\|^2 - \beta_i(2\gamma_i - \beta_i) \frac{(f(\mathbf{w}_i) - f^*)^2}{\|\mathbf{d}_i\|^2}$. Con $\beta_i = \gamma_i$ il fattore è $\gamma_i(2\gamma_i - \gamma_i) = \gamma_i^2 \geq \gamma_{\min}^2$. Telescopando e usando $\|\mathbf{d}_i\| \leq L$ si ottiene $\sum_i (f(\mathbf{w}_i) - f^*)^2 \leq L^2 \|\mathbf{w}_0 - \mathbf{w}^*\|^2 / \gamma_{\min}^2$, da cui il rate con $1/\gamma_{\min}$. Conteggio iterazioni: $k+1 \geq L^2 \|\mathbf{w}_0 - \mathbf{w}^*\|^2 / (\gamma_{\min}^2 \varepsilon^2)$, cioè il floor gonfia il numero di iterazioni di $1/\gamma_{\min}^2$. Con $\gamma_{\min} = 0.05$ è un fattore $400\times$. L’ordine $O(L^2/\varepsilon^2)$ resta invariato. **Trappola d’esame:** È un trade-off esplicito: $\gamma_{\min}$ piccolo $\rightarrow$ clip quasi inattivo (passo localmente ottimale) ma costante peggiore; grande $\rightarrow$ costante migliore ma memoria indebolita. Devi saper dire entrambi i lati. Rif.: report dim. Teorema DSM, “Telescoping” e “Iteration count”.

D22. Se la deflection non migliora il tasso asintotico, perché usarla?

Perché l’ordine $O(1/\sqrt{k})$ è il peggior caso; la deflection migliora la costante pratica riducendo lo zig-zag su problemi mal condizionati (analogamente a come il gradiente coniugato accelera il gradient descent senza cambiare la classe). Empiricamente converge più in fretta nelle prime fasi. Il guadagno è nella pratica, non nel bound asintotico — ed è onesto dirlo così. Rif.: report §“dsm_motivation” e “dsm_properties”.

D23. Quale subgradiente usate per il LASSO? È il minimo-norma?

$\mathbf{g} = \mathbf{X}^\top(\mathbf{X}\mathbf{w} - \mathbf{y}) + \lambda \mathbf{s}$ con $s_i = \text{sign}(w_i)$ e convenzione $\text{sign}(0) = 0$ (ammissibile, $0 \in [-1, 1] = \partial|0|$). *Non è l'elemento di minima norma di ∂f , ma il teorema richiede solo ammissibilità, non minima norma*: la disuguaglianza del subgradiente vale senza tolleranza (oracolo esatto, $\sigma = 0$). L'evento $(w_i)_j = 0$ esatto ha probabilità nulla per $i \geq 1$, quindi la convenzione si usa di fatto solo al cold start. **Trappola d'esame**: Distinzione fine: scegliere $s_i = 0$ non rende il subgradiente "inesatto" — σ misura l'errore dell'oracolo, non la sub-ottimalità della scelta dentro ∂f . Influenza solo la costante L . Rif.: report §"dsm_subgrad"; tutorial DSM, mappatura notazione.

D24. Warm start (OLS) vs cold start: cosa cambia nel bound?

Il rate dipende da $\|\mathbf{w}_0 - \mathbf{w}^*\|$ in modo *moltiplicativo*. Cold start $\mathbf{w}_0 = \mathbf{0}$: distanza $\|\mathbf{w}^*\|$, costo iniziale $O(M)$. Warm start OLS $\mathbf{w}_0 = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$: distanza $\|\mathbf{w}_{\text{OLS}} - \mathbf{w}^*\|$, costo $O(MH^2 + H^3)$. Il warm start aiuta *solo se* $\|\mathbf{w}_{\text{OLS}} - \mathbf{w}^*\| < \|\mathbf{w}^*\|$, cosa che dipende dall'istanza (coincidono a $\lambda = 0$). *Non è "sempre meglio": va verificato per istanza*. **Trappola d'esame**: Non dire "il warm start è sempre vantaggioso". Dipende dal rapporto delle due distanze; il teorema non pone condizioni su $\mathbf{w}_0$. Rif.: report §"dsm_parameters" e "dsm_properties".

D25. Il DSM produce soluzioni sparse? Come si termina?

Il rate controlla $\bar{f}^i - f^*$, non le singole coordinate: un passo di subgradiente aggiorna ogni componente in modo continuo e *non impone mai* $(w_i)_j = 0$ esatto. Il residuo sulle componenti inattive è dell'ordine del rate $O(L/(\gamma_{\min} \sqrt{i}))$, quindi la sparsità "dura" richiede una sogliatura a posteriori sopra questa scala. *Anche terminare con $\|\mathbf{g}_i\| \rightarrow 0$ è inaffidabile* ($\mathbf{0} \in \partial f$ vale solo in $\mathbf{w}^*$, non sugli iterati a budget finito): si usa $i_{\max}$ o un test di stagnazione su $\bar{f}^i$. Rif.: report §"dsm_properties".

Capitolo 17

Domande — Ottimizzazione Smooth e Intorno

D26. Cosa significa L -smooth e τ -fortemente convessa? Cos'è κ ?

L -smooth: ∇f è L -Lipschitz, equivalentemente $\nabla^2 f \preceq LI$; dà il *lemma di discesa* $f(\mathbf{x} + \mathbf{d}) \leq f(\mathbf{x}) + \nabla f^\top \mathbf{d} + \frac{L}{2} \|\mathbf{d}\|^2$ (modello quadratico superiore). τ -fortemente convessa: $\nabla^2 f \succeq \tau I$, modello quadratico inferiore. Il rapporto $\kappa = L/\tau$ è il numero di condizionamento dell'ottimizzazione: $\kappa \gg 1 \Rightarrow$ problema difficile (valle stretta e allungata). Per il nostro g : $L = \lambda_{\max}(\mathbf{X}^\top \mathbf{X})$, $\tau = \lambda_{\min}(\mathbf{X}^\top \mathbf{X})$ (a meno del fattore della convenzione $\frac{1}{2}$). Rif.: Cap. 3.1.3.

D27. Tassi del **gradient descent** nei vari regimi?

Convessa L -smooth, passo $1/L$: $f(\mathbf{x}_k) - f^* \leq L \|\mathbf{x}_0 - \mathbf{x}^*\|^2 / (2k)$, cioè $O(1/k)$ (sub-lineare). Fortemente convessa: $\|\mathbf{x}_k - \mathbf{x}^*\|^2 \leq (1 - 1/\kappa)^k \|\mathbf{x}_0 - \mathbf{x}^*\|^2$, cioè lineare con fattore $1 - 1/\kappa$. Quadratica con passo ottimo: fattore $((\kappa - 1)/(\kappa + 1))^k$. Nesterov: $O(1/k^2)$, ottimale per la classe smooth convessa. Rif.: Cap. 2.2; tabella tassi in appendice.

D28. Newton: idea, tasso, limiti.

Newton minimizza a ogni passo il *modello quadratico locale*: $\mathbf{d}_k = -H_f(\mathbf{x}_k)^{-1} \nabla f(\mathbf{x}_k)$. Vicino a un minimo con $H_f \succ 0$ converge *quadraticamente* ($\|e_{k+1}\| \leq C \|e_k\|^2$). Limiti: costo $O(H^3)$ per passo (fattorizzazione dell'Hessiana), H_f può non essere $\succ 0$ lontano dall'ottimo, non è globalmente convergente senza damping/line search. Rimedi: damped Newton, Newton regolarizzato ($H + \mu I$, legame con trust-region), Newton inesatto (risolvi $H\mathbf{d} = -\nabla f$ con CG). Rif.: Cap. 3.3.

D29. BFGS e quasi-Newton: cosa approssimano e perché funzionano?

Approssimano H_f^{-1} con aggiornamenti di rango basso usando solo i gradienti, imponendo la *condizione secante* $B_{k+1} \mathbf{s}_k = \mathbf{y}_k$ (con $\mathbf{s}_k = \mathbf{x}_{k+1} - \mathbf{x}_k$, $\mathbf{y}_k = \nabla f_{k+1} - \nabla f_k$). BFGS è l'aggiornamento di minima perturbazione che la soddisfa, mantiene $\succ 0$ se $\mathbf{y}_k^\top \mathbf{s}_k > 0$

(garantito da Wolfe) e ha **convergenza superlineare**. L-BFGS tiene solo le ultime m coppie: $O(mH)$ per passo, adatto a grande scala. *Rif.*: Cap. 2.4.

D30. CG per quadratiche: ottimalità sullo spazio di Krylov e tasso.

CG minimizza $f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^\top \mathbf{Q}\mathbf{x} - \mathbf{c}^\top \mathbf{x}$ ($\mathbf{Q} \succ 0$) e dopo k passi $\mathbf{x}_k$ è ottimo sullo spazio di Krylov $\mathcal{K}_k(\mathbf{Q}, \mathbf{r}_0)$; termina esattamente in $\leq n$ passi. Tasso: $\frac{\|\mathbf{x}_k - \mathbf{x}^*\|_{\mathbf{Q}}}{\|\mathbf{x}_0 - \mathbf{x}^*\|_{\mathbf{Q}}} \leq 2((\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1))^k$, con $\sqrt{\kappa}$ al posto di κ (molto meglio del GD). Con autovalori in m cluster, converge in $\sim m$ passi. *Rif.*: Cap. 2.5 e 6.3.

D31. Proximal gradient / ISTA / FISTA: quando e con che tasso?

Per $f = h + r$ con h L -smooth e r non-smooth “semplice” (es. $\lambda \|\cdot\|_1$): ISTA fa $\mathbf{x}_{k+1} = \text{prox}_{\alpha r}(\mathbf{x}_k - \alpha \nabla h(\mathbf{x}_k))$. Il prox di $\lambda \|\cdot\|_1$ è il *soft-thresholding* $[\cdot]_i = \text{sign}(v_i) \max(|v_i| - \alpha\lambda, 0)$, che dà zeri esatti. Tasso: ISTA $O(1/k)$, FISTA (con momento alla Nesterov) $O(1/k^2)$. **Trappola d’esame**: Differenza con il DSM: il prox sfrutta la struttura $h + r$ e produce sparsità esatta; il DSM tratta f come generica non-smooth (solo subgradiente) e non dà zeri esatti. Sono approcci alternativi allo stesso LASSO. *Rif.*: Cap. 2.3.

D32. Metodi bundle: cosa migliorano rispetto al subgradiente puro?

Costruiscono un **modello piecewise-linear inferiore** di f accumulando i subgradienti passati ($f_B(\mathbf{x}) = \max_j \{f(\mathbf{x}^j) + \mathbf{g}_j^\top (\mathbf{x} - \mathbf{x}^j)\} \leq f$) e minimizzano $f_B + \frac{\mu}{2} \|\mathbf{d}\|^2$ (termine prossimale per stabilizzare). Distinguono **serious step** (discesa sufficiente, ci si sposta) e **null step** (si arricchisce solo il modello). Recuperano informazione del passato in modo più ricco della singola deflection, al costo di risolvere un QP per iterazione. *Rif.*: Cap. 2.4.

D33. Deflection nel caso smooth (NCG, Heavy Ball): che legame con il DSM?

Stessa idea ($\mathbf{d}^i = -\nabla f + \beta^i \mathbf{d}^{i-1}$) applicata al caso liscio: NCG (Fletcher-Reeves, Polak-Ribière, ecc.) e Heavy Ball, che per quadratiche fortemente convesse raggiungono il fattore $(\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$ del CG. Il DSM è l’analogo non-smooth: sostituisce ∇f con $\mathbf{g} \in \partial f$ e usa regole di deflection/stepsize più complesse per garantire convergenza. Nel liscio la deflection riduce il condizionamento effettivo; nel non-smooth riduce l’oscillazione da scelta del subgradiente. *Rif.*: Cap. 3.6.

Capitolo 18

Domande — Algebra Lineare Numerica

D34. Equazioni normali del LS: derivazione e quando sono risolubili.

$\min_{\mathbf{x}} \|\mathbf{Ax} - \mathbf{b}\|^2$: il minimo annulla il gradiente, $\mathbf{A}^\top(\mathbf{Ax} - \mathbf{b}) = 0$, cioè $\mathbf{A}^\top \mathbf{Ax} = \mathbf{A}^\top \mathbf{b}$. Geometricamente: il residuo è ortogonale a $\text{Im}(\mathbf{A})$, cioè $\mathbf{Ax}^*$ è la *proiezione ortogonale* di $\mathbf{b}$. Se $\mathbf{A}$ ha rango pieno colonna, $\mathbf{A}^\top \mathbf{A} \succ 0$ e la soluzione è unica. Rif.: Cap. 4.2.

D35. (CHIAVE NLA) Perché le equazioni normali sono numericamente pericolose? $\kappa(\mathbf{A}^\top \mathbf{A}) = ?$

Perché $\kappa(\mathbf{A}^\top \mathbf{A}) = \kappa(\mathbf{A})^2$: formare $\mathbf{A}^\top \mathbf{A}$ *eleva al quadrato* il numero di condizionamento. Se $\kappa(\mathbf{A}) = 10^6$, allora $\kappa(\mathbf{A}^\top \mathbf{A}) = 10^{12}$, vicino alla precisione di macchina $u \approx 2.2 \cdot 10^{-16}$: si perde quasi metà delle cifre. Per questo si preferisce risolvere il LS con QR (errore $\propto \kappa(\mathbf{A})$, non $\kappa(\mathbf{A})^2$). È esattamente il motivo per cui nel sotto-problema IRLS, se $\mathbf{X}$ è mal condizionata, CG/QR possono battere Cholesky sulle equazioni normali. Rif.: Cap. 7.1; report Cap. 1 (osservazione condizionamento).

D36. Cholesky: ipotesi, costo, e perché niente pivoting.

Se $\mathbf{M} = \mathbf{M}^\top \succ 0$ esiste unica $\mathbf{R}$ triangolare superiore con diagonale positiva tale che $\mathbf{M} = \mathbf{R}^\top \mathbf{R}$. Costo $\frac{1}{3}n^3$ (metà di LU, sfrutta simmetria + definitezza). Non serve pivoting per la stabilità: la definitezza positiva garantisce pivot positivi e backward stability. È anche un test di definitezza positiva (se fallisce, $\mathbf{M} \not\succ 0$). È il solver del sotto-problema IRLS. Rif.: Cap. 5.3.

D37. QR di Householder: come azzerava le colonne ed è stabile.

Un riflettore $\mathbf{H} = \mathbf{I} - 2\mathbf{v}\mathbf{v}^\top / \|\mathbf{v}\|^2$ è ortogonale e simmetrico; scegliendo $\mathbf{v} = \mathbf{x} \pm \|\mathbf{x}\| \mathbf{e}_1$ riflette $\mathbf{x}$ su $\|\mathbf{x}\| \mathbf{e}_1$, azzerando tutto sotto il primo elemento. Applicando n riflettori si triangularizza $\mathbf{A}$: $\mathbf{A} = \mathbf{QR}$, costo $2mn^2 - \frac{2}{3}n^3$. È backward stable ($\tilde{\mathbf{Q}}\tilde{\mathbf{R}} = \mathbf{A} + \mathbf{E}$, $\|\mathbf{E}\| = O(u\|\mathbf{A}\|)$), a differenza di Gram-Schmidt classico (perde ortogonalità). Per LS:

$\mathbf{R}\mathbf{x} = \hat{\mathbf{Q}}^\top \mathbf{b}$. **Trappola d'esame:** Scegli il segno $\mathbf{v} = \mathbf{x} + \text{sign}(x_1) \|\mathbf{x}\| \mathbf{e}_1$ per evitare cancellazione. Rif.: Cap. 8.2.

D38. SVD: enunciato, sottospazi fondamentali, pseudoinversa.

Ogni $\mathbf{A} \in \mathbb{R}^{m \times n}$ si scrive $\mathbf{A} = \mathbf{U}\Sigma\mathbf{V}^\top$ con $\mathbf{U}, \mathbf{V}$ ortogonali e $\Sigma = \text{diag}(\sigma_1 \geq \dots \geq \sigma_n \geq 0)$. Da essa: $\text{Im}(\mathbf{A}) = \text{span}(u_1, \dots, u_r)$, $\text{ker}(\mathbf{A}) = \text{span}(v_{r+1}, \dots, v_n)$ ($r = \text{rank}$). Pseudoinversa $\mathbf{A}^+ = \mathbf{V}\Sigma^+\mathbf{U}^\top$ con Σ^+ che inverte i $\sigma_i \neq 0$. Soluzione LS di norma minima: $\mathbf{x}^* = \sum_i \frac{u_i^\top \mathbf{b}}{\sigma_i} v_i$ — da cui si vede che σ_i piccoli *amplificano il rumore* (motiva Tikhonov). Rif.: Cap. 9.

D39. Teorema di Eckart-Young: cosa afferma e a cosa serve.

Il troncamento $\mathbf{A}_k = \sum_{i=1}^k \sigma_i u_i v_i^\top$ è il *miglior* approssimante di rango $\leq k$ in norma spettrale e di Frobenius, con $\|\mathbf{A} - \mathbf{A}_k\|_2 = \sigma_{k+1}$. È la base di PCA, compressione, riduzione di dimensionalità: si tengono le k direzioni a maggiore “energia” (σ_i grandi). Rif.: Cap. 9.2.

D40. Numero di condizionamento: definizione e significato. Cosa misura il residuo?

$\kappa(\mathbf{A}) = \|\mathbf{A}\| \|\mathbf{A}^{-1}\| = \sigma_1/\sigma_n$. Per $\mathbf{A}\mathbf{x} = \mathbf{b}$, una perturbazione relativa di $\mathbf{b}$ si amplifica al più di $\kappa(\mathbf{A})$ nella soluzione: se $\kappa = 10^6$ perdi 6 cifre. È anche la *distanza relativa dalla singolarità*: $1/\kappa(\mathbf{A})$ è la minima perturbazione relativa che rende $\mathbf{A}$ singolare. Test a posteriori: *residuo piccolo* ($\|\mathbf{r}\|/\|\mathbf{b}\| = O(u)$) *certifica backward stability*, *ma l'errore forward può restare grande se $\kappa \gg 1$* . Rif.: Cap. 7.1, 7.3.

D41. Cos'è la backward stability? Differenza tra errore backward e forward.

Un algoritmo è *backward stable* se l'output calcolato è il risultato *esatto* per un input leggermente perturbato: $\hat{\mathbf{y}} = f(\hat{\mathbf{x}})$ con $\|\hat{\mathbf{x}} - \mathbf{x}\|/\|\mathbf{x}\| = O(u)$. L'errore *forward* $\|\hat{\mathbf{y}} - \mathbf{y}\|/\|\mathbf{y}\|$ è limitato dalla relazione *forward* $\lesssim \kappa \cdot$ *backward*: *anche un algoritmo backward stable dà errore forward grande se il problema è mal condizionato*. Il condizionamento è proprietà del problema, la stabilità dell'algoritmo. Rif.: Cap. 7.3.

D42. CG come metodo di Krylov / GMRES: idee in due righe.

CG (per $\mathbf{Q} \succ 0$): ogni passo è un solo prodotto matrice-vettore, ideale per matrici sparse grandi; con preconditionatore $\mathbf{P} \approx \mathbf{Q}$ si rimodella lo spettro e si riduce κ . GMRES (non simmetriche): minimizza il residuo su $\mathbf{x}_0 + \mathcal{K}_k$, costruendo una base ortonormale con Arnoldi; converge in fretta se gli autovalori sono in pochi cluster, ma costo/storage crescono $\Rightarrow$ si usa *restart*. Rif.: Cap. 6.3, 6.5.

Capitolo 19

Domande — Ottimizzazione Vincolata e Argomenti Distanti

D43. Condizioni KKT: enunciato e significato di complementarità.

Se $\mathbf{x}^*$ è minimo locale e vale LICQ, esistono moltiplicatori $\mu^* \geq 0$, λ^* con: stazionarietà $\nabla f + \sum \mu_i \nabla g_i + \sum \lambda_j \nabla h_j = 0$; ammissibilità; non negatività $\mu_i^* \geq 0$; *complementarità* $\mu_i^* g_i(\mathbf{x}^*) = 0$. Quest'ultima dice: o il vincolo è inattivo ($g_i < 0$) e $\mu_i^* = 0$, o è attivo ($g_i = 0$) con $\mu_i^* \geq 0$. Geometricamente: $-\nabla f$ sta nel cono normale all'ammissibile, non si migliora lungo direzioni ammissibili. *Rif.:* Cap. 13.2.

D44. Dualità lagrangiana: weak/strong duality e Slater.

La duale $q(\mu, \lambda) = \inf_{\mathbf{x}} L(\mathbf{x}, \mu, \lambda)$ è *sempre concava*; weak duality: $q(\mu, \lambda) \leq f^*$ per ogni $\mu \geq 0$ (lower bound). Lo *strong duality* ($f^* = q^*$, gap nullo) vale per problemi convessi sotto la condizione di Slater (esiste un punto strettamente ammissibile). Per LP vale sempre quando entrambi sono ammissibili. *Rif.:* Cap. 4.3.

D45. Frank-Wolfe vs gradiente proiettato: differenza chiave.

Gradiente proiettato: $\mathbf{x}_{k+1} = \Pi_S(\mathbf{x}_k - \alpha \nabla f)$, richiede di saper *proiettare* su S . Frank-Wolfe (conditional gradient): linearizza f e risolve un problema *lineare* su S ($\mathbf{s}_k = \arg \min_{\mathbf{x} \in S} \nabla f^\top \mathbf{x}$), poi fa un passo verso $\mathbf{s}_k$; evita la proiezione (utile quando la minimizzazione lineare è più facile, es. politopi). Tasso $O(1/k)$. *Rif.:* Cap. 13.4.2.

D46. Golden Section e Newton 1D: a cosa servono e con che velocità.

Sono per l'ottimizzazione univariata (es. line search). Golden Section: per f unimodale, riduce l'intervallo di un fattore $\tau \approx 0.618$ a ogni passo con *una* valutazione, costo $O(\log 1/\varepsilon)$, non usa derivate. Newton 1D: $x_{k+1} = x_k - f'(x_k)/f''(x_k)$, convergenza *quadratica* vicino a una radice di f' con $f'' \neq 0$, ma serve la derivata seconda e la vicinanza. *Rif.:* Cap. 12.2.

Capitolo 20

Domande Trasversali — Collegamenti NLA $\leftrightarrow$ Ottimizzazione

D47. In che senso il CG è “sia ottimizzazione sia algebra lineare”?

Risolvere $\mathbf{Q}\mathbf{x} = \mathbf{v}$ con $\mathbf{Q} \succ 0$ è equivalente a minimizzare la quadratica $\frac{1}{2}\mathbf{x}^\top \mathbf{Q}\mathbf{x} - \mathbf{v}^\top \mathbf{x}$ (stesso punto stazionario). Il CG è la *stessa* ricorrenza letta nei due modi: come solver iterativo di Krylov e come metodo di ottimizzazione con direzioni $\mathbf{Q}$ -coniugate. Per questo compare in entrambe le metà del corso e nel sotto-problema IRLS. *Rif.:* Cap. 2... e Cap. Riepilogo.

D48. Dove l'algebra lineare entra negli algoritmi del progetto?

In IRLS è *ovunque*: ogni iterazione è un sistema SPD $\mathbf{Q}_k \mathbf{w}_{k+1} = \mathbf{b}$ risolto con Cholesky o CG, e la stabilità dipende da $\kappa(\mathbf{Q}_k)$ che eredita $\kappa(\mathbf{X})^2$ dalle equazioni normali. Il *warm start OLS* è a sua volta un LS. Nel DSM l'algebra lineare è leggera (solo prodotti matrice-vettore $\mathbf{X}^\top(\mathbf{X}\mathbf{w} - \mathbf{y})$, $O(MH)$), ed è proprio questo a renderne l'iterazione cheap rispetto a IRLS. *Rif.:* report Cap. 2 e 4; Cap. Riepilogo.

D49. (Trappola di convenzione) Il subgradiente del LASSO ha o no il fattore 2?

Dipende dalla convenzione sulla loss. Nel report la loss è $g(\mathbf{w}) = \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2$, quindi $\nabla g = \mathbf{X}^\top(\mathbf{X}\mathbf{w} - \mathbf{y})$ e il subgradiente è $\mathbf{g} = \mathbf{X}^\top(\mathbf{X}\mathbf{w} - \mathbf{y}) + \lambda \mathbf{s}$ (*senza* 2). Se invece si scrive la loss *senza* $\frac{1}{2}$ (come in alcune sezioni della dispensa), compare $2\mathbf{X}^\top(\mathbf{X}\mathbf{w} - \mathbf{y}) + \lambda \mathbf{s}$. È lo stesso problema a meno di riscalare λ ; l'importante è essere coerenti. **Trappola d'esame:** All'orale verifica subito quale convenzione hai usato prima di scrivere il gradiente: un fattore 2 fuori posto fa cadere anche la costante di Lipschitz L . *Rif.:* report §“intro_optimality” (con $\frac{1}{2}$) vs Cap. 1.3 (senza).

D50. Tikhonov / ridge via SVD: legame col bias-variance.

$\min_{\mathbf{x}} \|\mathbf{Ax} - \mathbf{b}\|^2 + \delta \|\mathbf{x}\|^2$ ha soluzione $\mathbf{x}_\delta = \mathbf{V} \text{diag}(\sigma_i/(\sigma_i^2 + \delta)) \mathbf{U}^\top \mathbf{b}$: il filtro $\sigma_i/(\sigma_i^2 + \delta)$ *smorza* i σ_i piccoli (quelli che amplificano il rumore). δ grande $\rightarrow$ più bias, meno varianza; $\delta \rightarrow 0 \rightarrow$ soluzione LS instabile. È il ridge (L_2); il LASSO (L_1) del progetto fa la stessa funzione regolarizzante ma promuove *sparsità* invece di solo restringere la norma. *Rif.:* Cap. 4.1; Cap. Riepilogo.

Appendice A

Appendice: Richiami e Tabelle di Riferimento

A.1 Notazione

Simbolo	Significato
$A \in \mathbb{R}^{m \times n}$	Matrice $m \times n$ reale
$A^\top$	Trasposta
A^{-1}	Inversa (A quadrata non singolare)
A^+	Pseudoinversa di Moore-Penrose
$\ v\ _2$	Norma euclidea
$\ A\ _2$	Norma spettrale $= \sigma_1(A)$
$\ A\ _F$	Norma di Frobenius $= \sqrt{\sum \sigma_i^2}$
$\kappa(A)$	Numero di condizionamento $= \sigma_1/\sigma_n$
$\sigma_i(A)$	i -esimo valore singolare
$\lambda_i(A)$	i -esimo autovalore
$Q \succ 0$	Q definita positiva
$Q \succeq 0$	Q semidefinita positiva
$\mathcal{K}_k(A, b)$	Spazio di Krylov di ordine k
$u \approx 2.2 \times 10^{-16}$	Precisione di macchina (double)
$\partial f(x)$	Subdifferenziale di f in x
$\text{prox}_{\alpha f}(v)$	Operatore prossimale

A.2 Costi computazionali principali

Operazione	Costo (flop)	Note
$Av, A \in \mathbb{R}^{m \times n}$	$2mn$	matrice-vettore
$A^\top A$	mn^2	non fare se evitabile
Sostituzione triangolare $n \times n$	n^2	forw./back. subst.
LU (con pivoting)	$\frac{2}{3}n^3$	
Cholesky	$\frac{1}{3}n^3$	A SPD
QR (thin, $m \geq n$)	$2mn^2 - \frac{2}{3}n^3$	Householder
SVD (thin, $m \geq n$)	$O(mn^2)$	
Eigendecomp. $n \times n$	$O(n^3)$	
CG, k passi	$k \cdot (2 \text{nnz}(A) + O(n))$	
GMRES, k passi	$k \cdot (2 \text{nnz}(A) + O(kn))$	storage cresce!

A.3 Tassi di convergenza degli algoritmi di ottimizzazione

Metodo	Tasso	Ipotesi
GD, passo fisso	$O(L/k)$	f convessa L -smooth
GD, passo fisso	$\left(1 - \frac{1}{\kappa}\right)^k$	f str. convessa
GD, quadratica	$\left(\frac{\kappa-1}{\kappa+1}\right)^k$	f quadratica, α ottimo
Nesterov/FISTA	$O(L/k^2)$	f convessa L -smooth
CG	$2 \left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^k$	$Q \succ 0$
Newton (locale)	$O(\ e_k\ ^2)$ quadratica	$f \in C^3$, vicino a x^*
BFGS	$o(\ e_k\)$ superlineare	f smooth str. conv.
Subgradiente	$O(G/\sqrt{k})$	f convessa G -Lipschitz
ISTA/prox grad.	$O(L/k)$	$f = h + r$, h L -smooth

A.4 Regole pratiche per l'esame

Scelta dell'algoritmo di ottimizzazione

- f smooth convessa, n piccolo: GD o Newton.
- f smooth convessa, n grande: L-BFGS o CG (per quadratiche).
- $f = h + r$ separabile smooth+nonsmooth: ISTA/FISTA (proximal gradient).

- f nonsmooth in generale: metodo del subgradiente o bundle.
- Problema vincolato convesso: gradiente proiettato, Frank-Wolfe, o interior point.

Scelta del metodo per sistemi lineari $Ax = b$

- A SPD, densa: Cholesky ($\frac{1}{3}n^3$).
- A simmetrica indef., densa: $LDL^\top$.
- A generica, densa: LU con pivoting.
- A SPD sparsa: PCG (CG preconditionato).
- A sparsa non simm.: GMRES preconditionato.
- LS $\|Ax - b\|$, A densa: QR (preferire a equazioni normali).
- LS con dati noisy: regolarizzazione Tikhonov via SVD.

Bibliografia

- [1] L.N. Trefethen e D. Bau III, *Numerical Linear Algebra*, SIAM, 1997.
- [2] J.W. Demmel, *Applied Numerical Linear Algebra*, SIAM, 1997.
- [3] A. Frangioni, *Optimization & Learning — Lecture Notes 2025/26*, Università di Pisa, 2025.
- [4] D.P. Bertsekas, *Nonlinear Programming*, 3rd ed., Athena Scientific, 2016.
- [5] J. Nocedal e S.J. Wright, *Numerical Optimization*, 2nd ed., Springer, 2006.
- [6] S. Boyd e L. Vandenberghe, *Convex Optimization*, Cambridge University Press, 2004.
- [7] G. Strang, *Linear Algebra and Learning from Data*, Wellesley-Cambridge Press, 2019.
- [8] S. Bubeck, *Convex Optimization: Algorithms and Complexity*, arXiv:1405.4980, 2015.

Domande d'Esame Orale — Aggiunta

Il floor $\gamma_{\min}$: necessità teorica (intrinseca o scelta di stepsize?)

Addendum alla dispensa CM. Enunciati verificati verbatim sul paper d'Antonio–Frangioni (2009).

D51. Il floor $\gamma_{\min} > 0$ era intrinsecamente necessario, o conseguenza della vostra scelta di stepsize?

Intrinseco al metodo deflesso in questo framework, non conseguenza dell'accoppiamento specifico. La Polyak corretta del paper, eq. (3.1), impone

$$0 \leq \beta_k \leq \alpha_k \leq 1,$$

dove, con la mappatura del report, $\alpha_k = \gamma_i$ (coefficiente di deflection) e $\beta_k = \beta_i$ (moltiplicatore di stepsize). Il vincolo $\beta_k \leq \alpha_k$ è *cablato* dentro la (3.1): lo stepsize non può eccedere la deflection. La condizione (3.5) chiede $\beta_k \geq \beta^* > 0$ quando $\lambda_k \geq 0$; combinando,

$$\beta^* \leq \beta_k \leq \alpha_k = \gamma_i \implies \gamma_i \geq \beta^* > 0.$$

Quindi imporre β^* *costringe* $\gamma_i \geq \beta^*$: “mettere il bound β^* ” e “mettere $\gamma_{\min}$ ” sono lo *stesso* vincolo, non due opzioni. Il report pone $\beta_i = \min(1, \gamma_i) = \gamma_i$ (dato $\gamma_i \leq 1$), dunque $\beta^* = \gamma_{\min}$ senza alcun gioco.

Trappola d'esame: La variante *deflection-restricted* (Sez. 4 del paper) **non** evita il floor: la sua condizione (4.4), esplicitamente “analogous to (3.5)”, impone $\alpha_k \geq \alpha^* > 0$ quando $\lambda_k \geq 0$. La deflection va tenuta lontana da zero in *entrambe* le varianti. Quindi all'orale: il floor non è artefatto di $\beta_i = \min(1, \gamma_i)$, è richiesto dal framework Polyak-corretto-deflesso.

D52. Perché basta un bound positivo? (il ruolo della serie divergente)

La convergenza col target level richiede la serie (3.25), $\sum_k \lambda_k / \|\mathbf{d}_k\|^2 = \infty$. Subito sopra la (3.25) il paper osserva che η_k è maggiorato da una quantità negativa e che β_k è “bounded away from zero”, il che lascia spazio a $\delta_k \rightarrow 0$ “provided only that λ_k does not vanish too quickly”. Il floor tiene $\beta_k \geq \beta^*$ e impedisce che i passi diventino sommabili: senza, i pesi γ_i^2 nel telescoping

$$\sum_i \gamma_i^2 \frac{(f(\mathbf{w}_i) - f^*)^2}{\|\mathbf{d}_i\|^2} \leq \|\mathbf{w}_0 - \mathbf{w}^*\|^2$$

si annullano e la somma finita non forza più $f(\mathbf{w}_i) \rightarrow f^*$ (sono i pesi a renderla piccola, non il gap). Il Lemma 3.8, enunciato “under condition (3.5)”, usa proprio $\beta^* > 0$ per minorare lo spostamento $s_k = \|\mathbf{w}_{k+1} - \mathbf{w}_k\| = \beta_k \lambda_k / \|\mathbf{d}_k\|$ e ottenere $\sum_k s_k = \infty$ (infiniti reset).

D53. Cosa resta libero, allora?

Tre gradi di libertà reali:

1. **Non deflettere** ($\gamma_i \equiv 1$, subgradiente puro): $\gamma \equiv 1$ supera banalmente ogni floor, ma si perde l'effetto anti-zigzag. È l'unico modo di *eludere* del tutto la questione.
2. **Come si impone il bound**: floor fisso $\gamma_{\min}$, oppure reset $\gamma_i = 1$ quando i subgradienti si allineano. Sono due *implementazioni* dello stesso requisito $\alpha_k \geq \alpha^* > 0$,

non due modi di evitarlo.

3. Il valore $\gamma_{\min} = 0.05$: libero entro il range che converge (lo sweep dà gap finale in $[10^{-7}, 10^{-5}]$ per $\gamma_{\min} \in \{0.05, 0.1, 0.2, 0.5\}$).

Trappola d'esame: Conferma empirica su ELM LASSO: senza floor ($\gamma_{\min} = 0$) il gap si inchioda a $\sim 3.7 \cdot 10^{-2}$ (γ_i collassa sotto 10^{-10} dall'iterazione ~ 50 , lo skip-safeguard scatta sul 98% dei passi, δ si contrae ~ 2 volte invece di ~ 19); con $\gamma_{\min} = 0.05$ scende a $\sim 10^{-4}$. Osservato su tutti i 15 seed non-floored.

Rif.: Paper d'Antonio–Frangioni (2009), enunciati verificati verbatim: (3.1) $0 \leq \beta_k \leq \alpha_k \leq 1$; (3.5) bound uniforme $\beta^* > 0$; (3.25) serie divergente; (3.26) threshold; (4.4) condizione analoga per il caso deflection-restricted; Lemma 3.8. Report: cap. 3 (chapter3.tex righe 33, 165–175) e appendice.